

PROGRAMA DE PÓS-GRADUAÇÃO EM ANIMAIS SELVAGENS

RONALDO GARCIA RIBEIRO PUGLIA

**A APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL NO MONITORAMENTO
COMPORTAMENTAL DE TAMANDUÁ-MIRIM (*Tamandua tetradactyla*) E
ONÇA-PINTADA (*Panthera onca*) EX SITU.**

Botucatu-SP

Setembro de 2023

UNIVERSIDADE ESTADUAL PAULISTA
FACULDADE DE MEDICINA VETERINÁRIA E ZOOTECNIA

**A APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL NO MONITORAMENTO
COMPORTAMENTAL DE TAMANDUÁ-MIRIM (*Tamandua tetradactyla*) E
ONÇA-PINTADA (*Panthera onca*) EX SITU.**

RONALDO GARCIA RIBEIRO PUGLIA

Dissertação apresentada junto ao Programa de
Pós-Graduação em Animais Selvagens para a
obtenção do título de Mestre.

Orientador: Prof. Dr Carlos Roberto Teixeira

FICHA CATALOGRÁFICA ELABORADA PELA SEÇÃO TÉC. AQUIS. TRATAMENTO DA INFORM.
DIVISÃO TÉCNICA DE BIBLIOTECA E DOCUMENTAÇÃO - CÂMPUS DE BOTUCATU - UNESP

BIBLIOTECÁRIA RESPONSÁVEL: ROSANGELA APARECIDA LOBO-CRB 8/7500

Puglia, Ronaldo Garcia Ribeiro.

A aplicação de inteligência artificial no monitoramento comportamental de tamandua-mirim (*Tamandua tetradactyla*) e onça pintada (*Panthera onça*) ex-situ / Ronaldo Garcia Ribeiro Puglia. - Botucatu, 2023

Dissertação (mestrado) - Universidade Estadual Paulista "Júlio de Mesquita Filho", Faculdade de Medicina Veterinária e Zootecnia

Orientador: Carlos Roberto Teixeira

Capes: 20406010

1. Bem-estar. 2. Comportamento animal. 3. Inteligência artificial. 4. Redes neurais (Computação). 5. Animais de zoológico.

Palavras-chave: Bem-estar; Comportamento animal; Inteligência artificial; Rede neural artificial; Zoológico.

CARTA

Mini Biografia do Autor

Graduado em ciências biológicas pela Universidade Paulista no ano de 2019, filho de médico veterinário de zoológicos, praticamente nascido em contato com animais selvagens, iniciou sua carreira profissional aos 15 anos trabalhando no biotério do zoológico “Parque ecológico do Matão”, localizado em Votorantim-SP, durante os anos de 1997 à 2001. Também atuou na empresa Sítio Reino Animal como tratador de animais e coordenador de educação ambiental durante os anos de 2004 à 2009. Em janeiro de 2010 iniciou o trabalho como tratador de animais no zoológico municipal “Quinzinho de Barros”, em Sorocaba-SP durante os anos de 2010 a 2014. Durante esse período também idealizou e fundou a empresa Reino Animal Cursos, onde ministrou e organizou diversos cursos de biologia e manejo de animais selvagens para centenas de estudantes da área. No ano de 2014, fundou a empresa Zooterrarium que existe até hoje, está localizada na cidade de Sorocaba-SP, e especializada em animais pet não convencionais, alimentos vivos, terrários, lâmpadas, etc. Em 2021, iniciou o mestrado na Pós graduação em Animais Selvagens do programa da UNESP–Botucatu-SP. Atualmente trabalha também como coordenador do departamento de operacional e de ambientações do zoológico ‘Animália Park’ localizado na cidade de Cotia- SP.

Nome do autor: **Ronaldo Garcia Ribeiro Puglia**

**TÍTULO A APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL NO
MONITORAMENTO COMPORTAMENTAL DE TAMANDUA-MIRIM
(*Tamandua tetradactyla*) E ONÇA-PINTADA (*Panthera onca*) EX SITU.**

COMISSÃO EXAMINADORA

Prof. Assistente Dr. Carlos Roberto Teixeira

Presidente e Orientador

Programa de Pós-Graduação em Biotecnologia da Universidade Estadual Paulista-
Faculdade de Medicina Veterinária e Zootecnia - FMVZ – UNESP – Botucatu-
São Paulo.

Prof. Assistente Dr. Rodrigo Hidalgo Friciello Teixeira

Programa de Pós-Graduação em Biotecnologia da Universidade Estadual Paulista-
Faculdade de Medicina Veterinária e Zootecnia - FMVZ – UNESP – Botucatu-
São Paulo.

Prof. Titular Dr. Ramiro das Neves dias Neto

Universidade Federal dos Vales Jequitinhonha e Mucurui- UFVJM Campus-Unaí-
Minas Gerais.

Data da Defesa: 19 de setembro de 2023

Agradecimentos

Em primeiro lugar gostaria de agradecer ao Universo por me proporcionar todas as condições para que eu exista e também aos meus pais que me deram a oportunidade de nascer e por serem as pessoas que mais me apoiam, me incentivam a não desistir e me deram as melhores condições que puderam. A minha irmã Flora Helena Puglia Felipe que também sempre me deu todo apoio possível. Meu pai, Lazaro Ronaldo Ribeiro Puglia, veterinário e apaixonado pelos animais selvagens me deu a genética e também pela convivência e experiência me proporcionou a oportunidade de ter a aptidão e amor em trabalhar com animais selvagens, minha Mãe Maria Madalena Garcia, minha maior admiradora e a pessoa mais importante da minha vida. Minha madrastra Kátia Regina Pereira Puglia pelo apoio em muitos momentos e principalmente na conclusão da minha faculdade, Fernanda dos Santos Ferreira por todo o suporte, apoio e meus filhos que são meu orgulho João Pedro Paes Puglia e Raoni Ferreira Puglia. Em segundo lugar agradeço todos meus professores, principalmente ao meu orientador Carlos Roberto Teixeira e Rodrigo Hidalgo Friciello Teixeira que acreditaram no meu projeto e me deram a oportunidade de realizar este trabalho, também a UNESP Botucatu-SP pela oportunidade de realizar o mestrado em animais selvagens proporcionando ótimas aulas, excelentes professores e apoiando meu projeto. Por último agradeço a empresa AIBDARE representada pelo professor Marcos Monte de Oliveira Alves e o empresário Jarlon Nogueira pelo patrocínio de todos os custos com pessoal, equipamentos de inteligência artificial e todo apoio no levantamento de dados e formação da rede neural, realizada pelo Christiano Belli e Rodrigo Cardoso Dos Santos. Agradecimento especial ao meu amigo, mestre e biólogo Marco Antônio Majolo, diretor do zoológico Animália Park pela oportunidade de realizar e dar apoio na idealização do projeto, e aos proprietários do Animália Park Anael Ubiratã Cerqueira Fahel e Ariel Goulart Fahel pela oportunidade e apoio com toda infraestrutura, equipamentos e autorização para a realização do projeto com os animais do plantel. O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) - Código de Financiamento 001.

This study was financed in part by the Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) - Finance Code 001.

Sumário

LISTA DE TABELAS.....	I
LISTA DE FIGURAS.....	II
RESUMO.....	III
ABSTRACT.....	IV
INTRODUÇÃO.....	1
REVISÃO BIBIOGRÁFICA.....	1
OBJETIVOS	11
MATERIAIS E MÉTODOS	12
RESULTADOS	21
DISCUSSÃO.....	21
CONCLUSÕES.....	29
REFERÊNCIAS	29

Lista de Tabelas

Tabela 1. Descrição dos padrões de atividade/inatividade	12
Tabela 2. Frequência relativa e absoluta de frames de padrões de atividade/inatividade do tamanduá-mirim (<i>Tamandua tetradctyla</i>)	22
Tabela 3. Frequência relativa e absoluta de frames de padrões de atividade/inatividade da onça-pintada (<i>Panthera onca</i>)	25

Lista de Figuras

I

Figura1. Comparação tecnologia de aprendizado de máquina e aprendizado profundo. A primeira rede neural simples a segunda rede neural com muitas camadas.....	5
Figura 2. Comparação do neurônio artificial com o neurônio natural.....	6
Figura 3. Ilustra um exemplo de detecção de objetos multiclasse utilizando o método YOLO.....	7
Figura 4. Esquema de fluxo ilustrando o projeto relacionado aos orangotangos e a expansão resultante da inteligência artificial (IA).....	10
Figura 5. Foto panorâmica obtida por câmera com o Google Pixel 5 do recinto indoor dos orangotangos do zoológico de Toronto. As caixas azuis mostram onde estão localizadas as cinco câmeras ao redor do perímetro do recinto	11
Figura 6. Ilustração da câmera dos modelos VIP-1430-D-G2 (dome).	13
Figura 7. Ilustração da câmera modelo VIP-1430-B-G (Bullet).....	13
Figura 8. Ilustração do gravador digital de vídeos modelo SVR 70128.	13
Figura 9. Foto do tratamento dos polígonos realizado no Python, indicando os pontos x e y do mapeamento.....	15
Figura 10. Mapa Animália Park, Cotia – SP.....	16
Figura 11. Foto dos exemplares de onças-pintadas (<i>Panthera onca</i>)	17
Figura 12. Ilustração da planta baixa do recinto de exemplar de onça-pintada (<i>Panthera onca</i>)	18

Figura 13. Foto do recinto dos exemplares de onça-pintada (<i>Panthera onca</i>)	19
Figura 14. Foto do exemplar de tamanduá-mirim (<i>Tamandua tetradactyla</i>)	19
Figura 15. Ilustração da planta baixa do recinto de exemplares de tamanduás- mirim (<i>Tamandua Tetradactyla</i>)	20
Figura 16. Foto do recinto dos exemplares de tamanduás-mirim (<i>Tamandua tetradactyla</i>)	20
Figura 17. Frequência absoluta de frames de padrões de atividade/inatividade do tamanduá-mirim (<i>Tamandua tetradactyla</i>)	23
Figura 18. Média de frequência relativa de frames de padrões de atividade/inatividade do tamanduá-mirim (<i>Tamandua tetradactyla</i>)	24
Figura 19. Frequência absoluta de frames de padrões de atividade/inatividade da onça-pintada (<i>Panthera onca</i>)	26
Figura 20. Média de frequência relativa de frames de padrões de atividade/inatividade da onça-pintada (<i>Panthera onca</i>)	27

PUGLIA, R.G.R. A APLICAÇÃO DE INTELIGENCIA ARTIFICIAL NO MONITORAMENTO COMPORTAMENTAL DE TAMANDUÁ-MIRIM (*Tamandua tetradactyla*) E ONÇA-PINTADA (*Panthera onca*) EX SITU. Botucatu, 2023. 49 p. Dissertação (Mestrado em Animais Selvagens – Cirurgia) – Faculdade de Medicina Veterinária e Zootecnia, Campus de Botucatu, Universidade Estadual Paulista.

RESUMO

Os zoológicos atualmente têm como seu principal pilar a conservação de espécies de animais selvagens, podendo contribuir com novas pesquisas, que são urgentes e de suma importância. Atualmente muitas tecnologias surgiram e poderão contribuir nestas pesquisas, tendo mais eficiência, agilidade, maior capacidade de análise e armazenamento de dados. A inteligência artificial é uma ciência recente, abrange diversos campos, desde uso geral, como aprendizado e percepção, até em áreas mais específicas como medicina, robóticas, filosofia, engenharia, biologia, segurança entre outras. O Zoológico Animália Park localizado no município de Cotia-SP, tem como seu principal objetivo atingir elevados níveis de bem-estar dos animais pertencentes ao plantel, para isto foi desenvolvido um sistema de inteligência artificial que irá mensurar e analisar dados dos comportamentos de animais, este trabalho teve como objetivo fornecer dados iniciais para a formação da rede neural da inteligência artificial. Foram selecionadas duas espécies, onça-pintada (*Panthera onca*) e tamanduá mirim (*Tamandua tetradactyla*), ambos os recintos foram monitorados por seis câmeras que coletaram dados durante 24 horas por dia obtendo 2.000 horas de imagens durante 45 dias. Os dados foram analisados e mensurados com a utilização da inteligência artificial, por meio de programas computacionais e algoritmos. Os resultados obtidos do padrão comportamental foram de 91,09% de inatividade e 8,91% de atividade para os dois indivíduos de onça-pintada (*Panthera onca*), de 80,84% de período de inatividade e 19,16% de atividade para o grupo de tamanduá mirim (*Tamandua tetradactyla*) durante o intervalo de observação.

Palavras-chave:. Bem-estar. Inteligência artificial. Rede neural artificial. Comportamento animal. Zoológico.

PUGLIA, R.G.R. THE APPLICATION OF ARTIFICIAL INTELLIGENCE IN BEHAVIORAL MONITORING OF TAMANDUA-MIRIM (*Tamandua tetradactyla*) AND JAGUAR (*Panthera onca*) EX SITU. Botucatu, 2023. 49 p. Dissertation (Master's in Wildlife Animals - Surgery) - Faculty of Veterinary Medicine and Animal Science, Botucatu Campus, São Paulo State University.

ABSTRACT

Zoos currently have as their main pillar the conservation of wild animal species and can contribute to new research, which is urgent and of utmost importance. Nowadays, many technologies have emerged and can contribute to these research efforts, offering greater efficiency, agility, and increased capacity for data analysis and storage. Artificial intelligence is a recent science that encompasses various fields, from general use like learning and perception to more specific areas such as medicine, robotics, philosophy, engineering, biology, and security, among others. Animália Park Zoo located in Cotia, SP, has as its main objective to achieve high levels of animal well-being. For this purpose, an artificial intelligence system was developed to measure and analyze animal behavior data. The objective of this study was to provide initial data for the formation of the artificial neural network. Two species were selected: jaguar (*Panthera onca*) and tamandua mirim (*Tamandua tetradactyla*). Both enclosures were monitored by six cameras that collected data 24 hours a day, resulting in 2,000 hours of footage over 45 days. The data were analyzed and measured using artificial intelligence through computer programs and algorithms. The obtained results for behavioral patterns were 91.09% of inactivity and 8.91% of activity for the two individuals of jaguar (*Panthera onca*), and 80.84% of inactivity and 19.16% of activity for the tamandua mirim (*Tamandua tetradactyla*) group during the observation period.

Keywords: Well-being. Artificial intelligence. Artificial neural network. Animal behavior. Zoological.

INTRODUÇÃO

Zoológicos modernos devem ter como seu principal objetivo a conservação da vida selvagem, tendo engajamento com os trabalhos de campo, captação de recursos, educação ambiental, colaboração em pesquisas e parcerias, conscientização pública para atingir seus objetivos [1]. Segundo a Associação Mundial de Zoológicos e Aquários, conservação consiste em um conjunto de ações que assegurem populações de espécies em habitats e ecossistemas naturais, em longo prazo e em qualquer lugar que isso seja possível [2].

Zoológicos e aquários detém o dever de proteção da fauna silvestre, utilizando as melhores práticas de manejo e cuidado em instituições e entre elas, adaptando técnicas intensivas para a proteção e preservação das espécies na natureza, apoiando pesquisas sociais e biológicas para a conservação [3]. Segundo MELOR, objetivo principal é a conservação de todas as espécies, incluindo a humanidade, promovendo ecossistemas saudáveis e sustentáveis por meio do asseguramento de populações de espécies em habitats naturais a longo prazo [4].

Os zoológicos e aquários possibilitam uma oportunidade sem igual para expandir o conhecimento sobre espécies animais selvagens, por conta de comportamento críptico, ambientes inacessíveis, acesso restrito aos animais, alto custo de estudo de um número suficiente de indivíduos e possibilidade do próprio estudo afetar os animais em questão [5]. As populações de animais selvagens mantidas em zoológicos e aquários oferecem acesso às amostras em longo prazo, fornecendo parâmetros de contexto e histórias de vida para melhor compreender o significado de dados coletados em um único momento [6].

O trabalho conjunto entre a ciência acadêmica e as instituições de zoológicos e aquários pode proporcionar um importante avanço na missão de conservação animal, ao possibilitar o desenvolvimento de estudos relevantes para aprimorar as práticas operacionais, promover a saúde e o bem-estar dos animais em cativeiro, além de gerar conhecimentos importantes sobre a reprodução, genética e nutrição desses seres [7]. Novas técnicas de pesquisa e tecnologias avançadas foram desenvolvidas por meio dos avanços científicos que não estão prontamente disponíveis para zoológicos e aquários [8]. Inúmeras parcerias bem-sucedidas entre a comunidade acadêmica e zoológicos e aquários

estão sendo construídas para melhorar a reprodução para conservação e bem-estar animal. Aumentar a compreensão da resiliência das espécies, promover pesquisa científica de alta qualidade e aumentar a credibilidade científica dessas instituições [9]. É essencial que sejam realizadas pesquisas científicas para estabelecer populações autossustentáveis de animais selvagens. Publicar estudos de pequena escala sobre a biologia e estratégias de manejo de animais selvagens é importante, mesmo que os resultados não sejam positivos, pois evita a duplicação de esforços, orienta decisões de gestão global, aumenta a compreensão da comunidade sobre complexidades de manejo da vida selvagem e fornece evidências de valor para gestores e colegas [10].

Comportamento animal de forma geral, é o conjunto de ações ou reações de um animal em relação ao ambiente e às outras espécies [11]. Isso inclui a busca por recursos alimentares, reprodução, defesa, comunicação e quaisquer outros comportamentos necessários para sua sobrevivência e adaptação ao meio ambiente. Comportamentos animais também podem ser influenciados por fatores genéticos, ambientais e aprendidos [12]. De modo geral, o comportamento é composto por diferentes ações exibidas pelos animais, as quais não se limitam apenas aos tipos de movimentação ou atividades relacionadas, como correr, saltar, nadar, cavar e alimentar-se [13]. O comportamento também envolve movimentos sutis e discretos em pequenas regiões do corpo, que podem ocorrer simultaneamente às ações mais visíveis, como a vocalização, movimentação das orelhas, balanço da cauda e liberação de odor [14].

A etologia é uma área da biologia que se dedica ao estudo do comportamento animal, que abrange todas as ações realizadas por um animal, inclusive aquelas aparentemente passivas como dormir ou descansar [15]. É importante entender que mesmo essas atitudes possuem uma finalidade e fazem parte do comportamento total do animal. Em resumo, comportamento é a soma de todas as ações e omissões de um animal [16].

O termo “etologia” surgiu por volta de 1750, em publicações da Academia Francesa de Ciências, porém, com um uso mais geral para descrição de histórias de vida. A utilização do termo em seu sentido atual, para descrever e estudar o comportamento animal e humano, só veio a ocorrer em 1950 [17]. A compreensão adequada da importância das ferramentas da etologia nos estudos da biodiversidade depende do reconhecimento do fato de que os animais constantemente tomam decisões, como escolher o que, como, quando e onde se alimentar [18].

Consequentemente, os animais apresentam mecanismos cognitivos e perceptuais que os ajudam em suas decisões diárias, que podem ter profundas implicações em sua sobrevivência, reprodução e adaptação [19]. É crucial entender que muitos comportamentos animais são imperceptíveis ao nosso universo sensorial por serem muito rápidos, muito lentos ou envolvendo a liberação de odores ou sons que não podemos perceber, com isso, pode-se definir o comportamento animal como algo complexo e diverso devido à variedade de mecanismos envolvidos [20].

O bem-estar animal tem recebido mais atenção em nossa sociedade, especialmente em relação a animais de pesquisa e exposição, para garanti-lo, é preciso conhecimento prévio, o que é obtido por meio da observação do comportamento e do bem-estar animal por especialistas em comportamento animal, tanto em laboratório quanto no campo [21]. Para prover boas condições para animais de fazendas, reprodução de espécies ameaçadas de extinção e cuidado apropriado para animais de companhia, é necessária uma base sólida de estudos do comportamento animal [18].

A onça-pintada (*Panthera onca*) é o maior felino do continente americano, ocorre do norte da Argentina até o sul dos Estados Unidos [22]. O peso pode variar entre 35 kg e 158 kg e o comprimento total pode atingir até 2,70 m [23]. No Brasil, é na região amazônica e no Pantanal que se encontram as maiores concentrações de onças-pintadas, havendo apenas pequenas populações em outros biomas brasileiros, com exceção dos pampas, onde essa espécie já foi extinta [24]. De acordo com a Lista Nacional de Espécies Ameaçadas de Extinção do Ministério do Meio Ambiente e a onça pintada no Brasil é classificada como vulnerável (VU) à extinção [25].

O tamanduá-mirim (*Tamandua tetradactyla*), também chamado de mixila ou tamanduá-de-colete, é pertencente à família Myrmecophagidae [26], e pode ser encontrado a leste dos Andes, desde as Guianas até o norte da Argentina e Uruguai [27]. No Brasil, essa espécie é amplamente distribuída em todos os biomas [28]. Possuem cerca de 47 a 77 cm de comprimento, uma cauda de 40 a 68 cm e pesam aproximadamente 7 kg [29]. Na Lista Vermelha das Espécies Ameaçadas de Extinção da União Internacional para a Conservação, ele aparece na categoria “Pouco preocupante” [30].

Durante milhares de anos, o homem procurou entender como seu cérebro é capaz de perceber, prever e manipular um mundo muito maior e mais complexo do que ele próprio

[31]. O campo da inteligência artificial se propõe a ir além e não somente compreender, mas construir entidades dotadas de raciocínio e inteligência [32].

A inteligência artificial surgiu após a Segunda Guerra Mundial e desde então se desenvolveu de forma exponencial, tornando-se potencialmente relevante para qualquer esfera de atividade intelectual humana [33]. Por ser capaz de automatizar tarefas intelectuais, a IA se tornou um campo universal de conhecimento [34].

A comunidade científica de Inteligência Artificial está dividida em dois grupos principais: uma abordagem baseada em regras lógicas, também conhecida como simbolistas, que define previamente as regras que um sistema deve seguir para resolver determinados problemas, e uma abordagem baseada em redes neurais, que segue um processo de aprendizado, inspirado pela arquitetura das camadas neurais do cérebro humano, onde as camadas neurais artificiais processam informações e determinam autonomamente o resultado final de suas operações com base em exemplos [35]. Enquanto a abordagem de aprendizado na primeira onda da IA resultou em grande frustração até a década de 1980, a segunda onda, que ocorreu nas últimas décadas, foi impulsionada por essa abordagem [36]. A partir dos anos 2000, houve uma revolução nos insumos da IA, como o processamento computacional e a disponibilidade de dados, além do notável avanço técnico no campo de aprendizado de máquina: o aperfeiçoamento das redes neurais, agora conhecidas como sistemas de aprendizado profundo [37].

Aprendizado profundo são modelos computacionais compostos por múltiplas camadas de processamento, têm a capacidade de aprender representações de dados com diferentes níveis de abstração, graças ao aprendizado profundo [38] (Figura 1). Essas técnicas têm apresentado melhorias significativas em várias áreas, incluindo reconhecimento de fala, reconhecimento de objetos visuais, detecção de objetos, descoberta de drogas e na área genômica, o aprendizado profundo descobre padrões complexos em grandes conjuntos de dados, utilizando o algoritmo de retro propagação para indicar como uma máquina deve ajustar os parâmetros internos em cada camada com base na representação da camada anterior [39].




FIGURA 1. Comparação tecnologia de aprendizado de máquina e aprendizado profundo. A primeira rede neural simples a segunda rede neural com muitas camadas [38].

Em outras palavras, o aprendizado profundo é capaz de aprender de maneira complexa, pois utiliza recursos simples aprendidos a partir de dados [40]. Por meio de redes neurais artificiais de múltiplas camadas não-lineares, conhecidas como arquiteturas de aprendizagem profunda, é possível descobrir representações hierárquicas de dados [41]. Os métodos conexionistas, ou Redes Neurais Artificiais (RNA), são baseados na observação da organização e funcionamento do cérebro humano, a estrutura da rede em que uma RNA é formada armazena seu conhecimento, com ênfase nas conexões (sinapses) entre as unidades (neurônios) que a constituem [42].

Nos modelos de redes artificiais simulados em computadores, cada conexão é atribuída um peso sináptico (valor numérico) que determina a intensidade da interconexão entre dois neurônios [43]. Para entender uma rede neural artificial (RNA), é necessário fazer um paralelo entre um neurônio biológico e artificial [44]. O neurônio biológico é formado pela soma que é o corpo do neurônio, pelo axônio que conduz o impulso nervoso de um neurônio para outro, por dendritos que são ramificações que fazem a comunicação entre um neurônio e as sinapses, que por sua vez propagam o sinal neural ativando a comunicação com o próximo neurônio [45] (Figura 02).




FIGURA 2. Comparação do neurônio artificial com neurônio natural [46].

O aprendizado de uma Rede Neural Artificial em realizar uma tarefa específica é alcançado através do treinamento da rede utilizando um conjunto de neurônios artificiais, relacionado ao problema de interesse [43].

Existem três tipos de aprendizado que podem ser utilizados para treinar uma RNA: o aprendizado supervisionado, em que é fornecida a resposta desejada e os pesos são ajustados; o aprendizado semi-supervisionado, em que a rede aprende com base nos resultados de sucesso e insucesso, mesmo sem saber exatamente como lidar com esses resultados; e o aprendizado não supervisionado, em que apenas os dados de entrada são fornecidos e a rede é capaz de se reorganizar até obter uma saída satisfatória [47].

Os algoritmos de aprendizado, que são procedimentos ou conjuntos pré-estabelecidos de regras, são utilizados para definir as redes neurais são algoritmos diferentes entre si pela maneira como ajustam o peso sináptico de um neurônio [48]. Este algoritmo utiliza o aprendizado supervisionado, no qual o treinamento ocorre por tentativa e erro [49]. No entanto, um dos inconvenientes do algoritmo é o tempo necessário para treinamento, que é influenciado pela taxa de atualização dos pesos [50]. Se a taxa definida for muito baixa, a rede levará muito tempo para treinar. Por outro lado, se a taxa for alta, a rede pode convergir mais rapidamente, mas torna-se instável quando apresentada a uma nova entrada, comprometendo a confiabilidade dos resultados [51].

Com o avanço dos computadores de propósito geral no final dos anos 90, tornou-se viável processar rapidamente grandes quantidades de dados [52]. A abordagem predominante envolvia extrair características locais da imagem, também conhecidas como vetor de características, e utilizar uma técnica de aprendizado de máquina para reconhecimento de

imagens [53]. Em 2016, foi apresentado um novo método de detecção de objetos multiclasse chamado de tiro único. Essa abordagem permite detectar vários objetos apenas fornecendo a imagem completa para rede neural artificial, sem a necessidade de digitalizar a imagem [54].

O método YOLO (You Only Look Once) é um exemplo representativo dessa abordagem, onde é gerado um retângulo de objeto e uma categoria de objeto para cada região local dividida por uma grade [55] (Figura 3). Inicialmente, são gerados mapas de características através de convolução e agrupamento das imagens de entrada. A posição (i, j) de cada canal no mapa de características obtidas representa uma região correspondente à grade (i, j) da imagem de entrada, e esse mapa é então enviado para camadas totalmente conectadas. Os valores de saída obtidos nessas camadas são o escore (20 categorias) da categoria do objeto em cada posição da grade, bem como a posição, tamanho e confiabilidade dos dois retângulos de objeto [55].

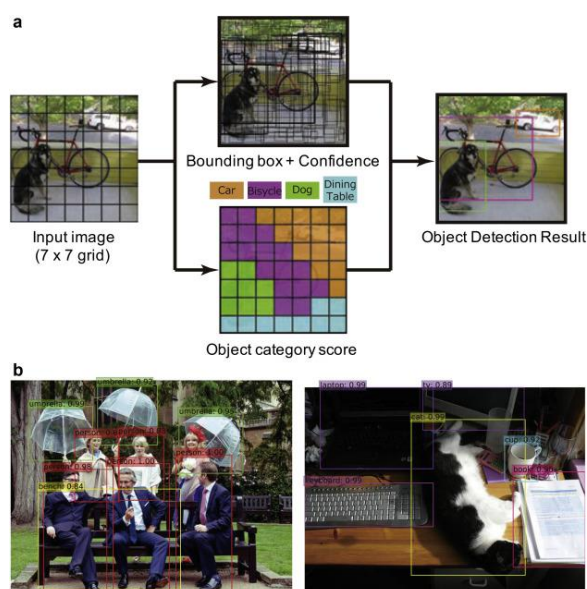


FIGURA 3. Ilustra um exemplo de detecção de objetos multiclasse utilizando o método YOLO [55].

Apenas recentemente a tecnologia tem conseguido monitorar o comportamento animal devido à sua complexidade [56]. Não basta apenas reconhecer o indivíduo em seu ambiente, mas também é necessário interpretar diferentes padrões de movimentos e de

características comportamentais distintas (como o comportamento agonístico e brincadeira, por exemplo) [57].

A pesquisa tradicional de comportamento envolve muitas horas de treinamento de pesquisadores e voluntários para identificar corretamente o comportamento animal com base em etogramas detalhados [58]. Da mesma forma, são necessárias várias horas e inúmeras imagens para treinar a inteligência artificial a "reconhecer" esses comportamentos distintos, a grande vantagem dessa tecnologia é a possibilidade de monitorar por períodos mais longos, dispensando a presença de observadores humanos, resultando assim em uma coleta massiva de dados [59].

Com os progressos tecnológicos recentes, o software de computador que utiliza aprendizado de máquina, aprendizado profundo e redes neurais artificiais foi desenvolvido para monitorar animais em relação à sua localização, identidade de espécie, identidade individual e/ou comportamento [60]. Zoológicos, aquários e áreas de conservação credenciadas utilizam as melhores práticas para monitorar seus animais e obter os dados comportamentais necessários de maneira eficiente [61]. Por exemplo, o aplicativo "ZooMonitor", de baixo custo, foi utilizado para rastrear hipopótamos-pigmeus e galinhas domésticas, fornecendo informações sobre sua aparência física, uso do habitat e comportamento em seus ambientes [62].

Tecnologias antigas, caras, invasivas e imprecisas estão sendo substituídas por softwares e algoritmos complexos, como as redes neurais profundas, que são capazes de identificar e reconhecer indivíduos de pandas gigantes [63]. Zoos modernos, como o Toronto Zoo, estão liderando os esforços para salvar espécies ameaçadas de extinção e garantir que os animais em seu cuidado vivam uma vida saudável e enriquecida em ambientes que sejam típicos de sua espécie. A coleta abrangente de dados de várias fontes é claramente crucial para fornecer aos tratadores de zoológico, trabalhadores de conservação e pesquisadores as informações necessárias para aprender mais sobre as espécies e indivíduos que estão sob sua supervisão, a fim de oferecer o melhor cuidado possível e explorar possibilidades adicionais de reintrodução e conservação [64].

Através do uso da tecnologia de IA e da coleta de extensos padrões de comportamento animal, com o objetivo de estabelecer um ambiente e banco de dados de detecção confiáveis, pretende-se obter um cuidado e gerenciamento inteligente dos animais [65]. A pesquisa sobre comportamento animal costuma ser realizada por

observadores que coletam dados em tempo real, seja através de anotações manuais em papel, caneta e prancheta, ou por meio de vídeos que são posteriormente rotulados manualmente. Infelizmente, esse método de coleta de dados pode ser demorado e tedioso, além de estar limitado às horas em que os observadores estão presentes [66].

Levando em consideração o software de Inteligência Artificial da EAIGLE (empresa alemã de inteligência artificial), surgiu uma oportunidade inovadora de parceria com uma instituição acadêmica (Universidade de York) é uma instituição sem fins lucrativos (Toronto Zoo Wildlife Conservancy) para desenvolver uma IA que preenche a lacuna na tecnologia atual. Essa IA tem o objetivo de rastrear em tempo real a localização dos orangotangos, identificar indivíduos, estimar sua postura (como ombros e cabeça) e monitorar seu comportamento com alto grau de especificidade. Inicialmente, o projeto está focado no orangotango de Sumatra (*Pongo abelii*), uma espécie criticamente ameaçada e parente próximo dos humanos para os quais a IA foi originalmente desenvolvida [64] (Figura 4). A equipe de pesquisa está coletando, preparando e analisando imagens dos orangotangos em seu recinto no zoológico enquanto a EAIGLE está treinando o modelo de IA. O objetivo desse modelo é identificar indivíduos, analisar seus comportamentos, bem como sua temperatura corporal e posição dos membros/articulações [64] (Figura 5). É essencial compreender como esses animais interagem com seus ambientes artificiais, considerando que passam suas vidas sob cuidados humanos. Isso inclui a análise de onde eles passam seu tempo e quais comportamentos executam ao longo do dia no interior do recinto. Por exemplo, é importante identificar onde os animais estão ativos em comparação onde estão descansando em seu habitat ou no recinto. Além disso, devemos observar se há mudanças nos padrões de alimentação, urinação e defecação que possam indicar problemas de saúde. Aumentos nos comportamentos agitados, agonísticos ou estereotipados podem sugerir aumento de estresse.

Compreender a interação desses animais com seu ambiente é crucial para realizar ajustes no layout de seu habitat, assegurando um estilo de vida típico de sua espécie e melhorando o enriquecimento tanto em nível de grupo quanto individual [67]. É importante ressaltar que mudanças no comportamento em relação aos padrões normais podem indicar possíveis problemas de saúde ou bem-estar em um indivíduo, além de fornecer dados gerais que podem auxiliar na melhoria da criação.

Dessa forma, a implantação dessa inteligência artificial terá um impacto significativo nos resultados e no bem-estar animal. A detecção de localização e o reconhecimento individual serão fundamentais para monitorar animais grávidas ou doentes, bem como acompanhar seu desenvolvimento desde a infância até a velhice. Uma habilidade que muitas tecnologias atuais ainda não possuem é a estimativa de movimento, ou seja, a capacidade de rastrear a posição do corpo. Essa capacidade não é apenas essencial para identificar eventuais problemas nas extremidades, mas também para entender os padrões de movimento determinados pelas posições das extremidades e articulações, que definem os comportamentos dos animais. Ao combinar todas essas capacidades, será possível preencher a lacuna existente na tecnologia atualmente disponível [64].

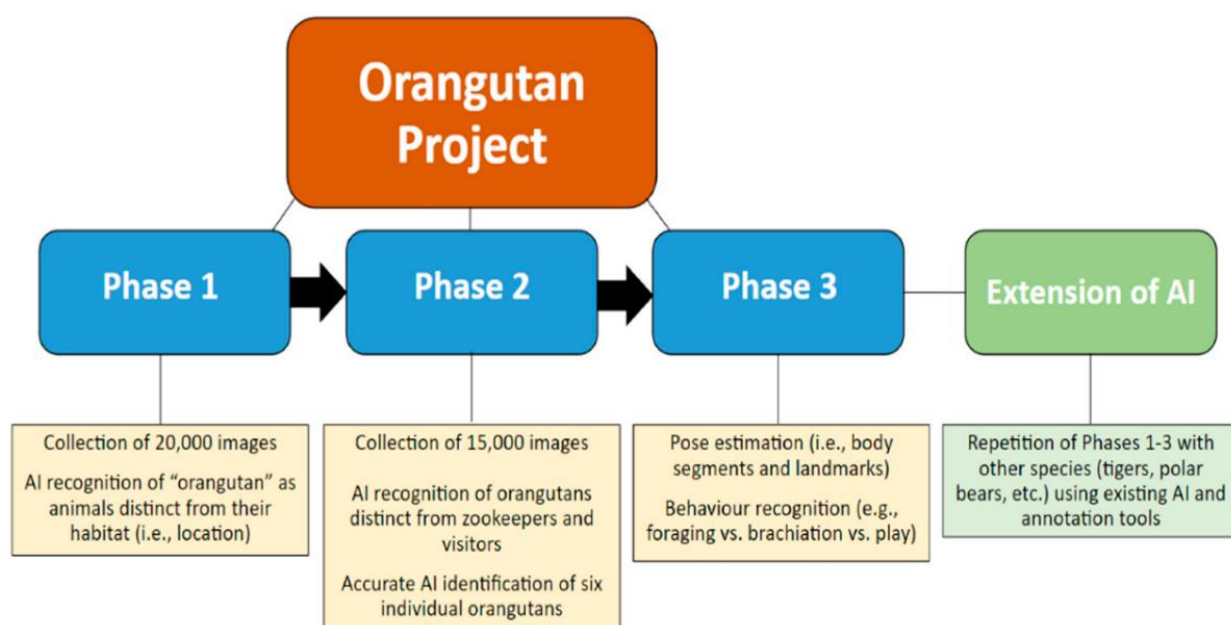


FIGURA 4. Esquema de fluxo ilustrando o projeto relacionado aos orangotangos e a expansão resultante da inteligência artificial (IA) [64].



FIGURA 5. Foto panorâmica obtida por câmera com o Google Pixel 5 do recinto indoor dos orangotangos do zoológico de Toronto. As caixas azuis mostram onde estão localizadas as cinco câmeras ao redor do perímetro do recinto [64].

Essa pesquisa tem o objetivo de elaborar padrões de comportamentos (atividade/inatividade) de onças-pintadas (*Panthera onca*) e tamanduás-mirins (*Tamandua tetradactyla*) mantidos sob cuidados humanos, por meio de imagens obtidas por filmadora para alimentar programas de IA.

Materiais e Métodos

Para a realizar esta pesquisa foram observados animais da espécie onça-pintada (*Panthera onca*) e tamanduá-mirim (*Tamandua tetradactyla*). Sendo um casal de onça pintada e oito indivíduos de tamanduá mirim, foram instaladas seis câmeras em cada recinto onde foram realizadas gravações por vinte e quatro horas por dia, durante o período de 45 dias, as imagens foram analisadas por média de frames (fotografia tirada a cada dez segundos do comportamento do animal) de cada espécie animal. Determinamos duas categorias para serem analisadas ativo e inativo (Tabela 1). Durante esse período obtivemos um total de duas mil horas de imagens analisadas. Como possíveis erros de detecção do animal por meio das câmeras podem ocorrer (pontos cegos, problemas no sistema, falta de energia elétrica), consideraremos sem perda de informação as proporções geradas pelos números de frames registrados superiores ou iguais a mil, em que o animal esteve inativo durante um dia. As gravações foram realizadas sem alteração da rotina dos animais, onde as 9 horas são soltas no recinto, as 17 horas são recolhidas para os cambiamentos onde ficam por todo período noturno. Também são realizadas atividades de enriquecimento ambiental três vezes por semana.

TABELA 1. Descrição dos padrões de atividade/inatividade.

Ativo	Inativo
Correr/andar/locomover-se	Repouso
Nadar	Parado
Escalar	Deitado
Farejar	
Beber água	
Alimentar-se	
Interagir	

Para a realização desse trabalho foram utilizados os seguintes equipamentos eletrônicos: doze câmeras dos modelos VIP-1430-D-G2 (dome), VIP-1430-B-G2 (Bullet), sete gravadores digitais de vídeos modelo SVR 70128, cabeamento da marca COMSCOPE

modelo Cat6e e os programas de computador YOLO, Powerbl e Opencv para processamento de imagens, Mysql para banco de dados e Panda para gerenciamento de dados de grandes volumes (Figura 6, 7 e 8).



FIGURA 6. Ilustração da câmera dos modelos VIP-1430-D-G2 (dome).



FIGURA 7. Ilustração da câmera modelo VIP-1430-B-G (Bullet).



FIGURA 8. Ilustração do gravador digital de vídeos modelo SVR 70128.

A metodologia de estudo utilizada envolve o uso do programa de computador YOLO para inferência em vídeos em tempo real, utilizando a linguagem Python. Após a aplicação da rede neural nos vídeos, os dados resultantes são compilados em um arquivo e separados por quebras de linha. Esse arquivo contém informações essenciais para a análise dos dados, como as coordenadas x e y das detecções, a identificação do animal detectado, o link para a imagem correspondente, a data e a hora da detecção e a câmera em que o animal foi registrado. Para obter insights a partir desses dados, foi realizada a delimitação de áreas de interesse nas imagens. Essas áreas são definidas estrategicamente e servem como referência para classificar o animal em estados de repouso ou atividade. O tratamento desses dados foi feito por meio de um script Python, que percorre o arquivo CSV e com base nas coordenadas x e y, determina em qual área o animal se encontrava em cada instante de detecção. O resultado desse processo foi a geração de um novo arquivo com as informações relevantes para a análise do comportamento animal. Esse novo arquivo foi construído com base nos dados capturados pelas câmeras, utilizando os eixos x e y. Foi criada uma grade em cada câmera para delimitar as áreas, a fim de padronizar e mapear o movimento do animal. Esse arquivo contém os valores das áreas, formando um polígono. Cada câmera foi tratada separadamente e, posteriormente, os pontos dos polígonos de todas as câmeras são combinados em um único arquivo para ser tratado no Python.

O tratamento dos polígonos foi realizado no Python (linguagem de programação de computador), onde os pontos x e y do mapeamento de cada área são lidos (Figura 9). Com base nesses pontos, foi feita uma verificação nos dados do outro arquivo, nos pontos centrais (x e y), para determinar em qual área o animal está. Essa verificação é realizada linha por linha do arquivo, resultando na identificação da área em que o animal se encontra em cada momento. Após essa etapa, foi criado um novo arquivo que compila todos os valores necessários para a análise do comportamento dos animais.

A análise dessas informações foi conduzida no software Power BI, uma plataforma robusta utilizada para criação e apresentação de dashboards interativos. Ao importar o arquivo resultante do tratamento dos dados, é possível extrair os insights necessários para

o estudo e a observação do comportamento animal. Entre as informações disponíveis, destacam-se o estado do animal (ativo ou em repouso) por dia, a relação das áreas visitadas pelo animal por hora/dia e o intervalo de datas selecionado para análise. Dessa forma, a metodologia empregada integra a capacidade do modelo YOLO de realizar detecções em tempo real com a análise detalhada dos dados resultantes, permitindo compreender e interpretar o comportamento dos animais monitorados. O Power BI proporciona uma visualização intuitiva e interativa dos dados, facilitando a identificação de padrões, tendências e correlações relevantes para a pesquisa e tomada de decisões.



FIGURA 9. Foto do tratamento dos polígonos realizado no Python, indicando os pontos x e y do mapeamento.

O projeto foi realizado no Zoológico Animália Park, que está localizado na cidade de Cotia, estado de São Paulo (Figura 10).




FIGURA 10. Mapa Animália Park, Cotia - SP

Recinto dos exemplares de onças-pintada (*Panthera onca*).

O recinto do exemplar de onça-pintada tem 418,66m², simulando o habitat natural dos animais incluindo topografia ondulada, solo, vegetação viva, troncos, rochas naturais e artificiais e corpo d'água com cachoeira. A barreira física é construída com paredes de alvenaria, colunas de aço e cabos de aço que suportam uma malha (aço revestido em tela 2,5" malha fio 14). A estrutura favorece vistas total do recinto externo e interno, além de apresentar uma visão submersa do lago aos visitantes. O edifício de cambiamento contém três salas individuais (em 9 m² cada) para a separação dos animais, sendo escondido atrás de uma paisagem de rocha. A visão do visitante da exposição é através de janelas de vidro (quatro painéis de vidro) sob um abrigo de observação (Figuras 11, 12 e 13).




FIGURA 11. Foto dos exemplares de onças-pintada (*Panthera onca*).

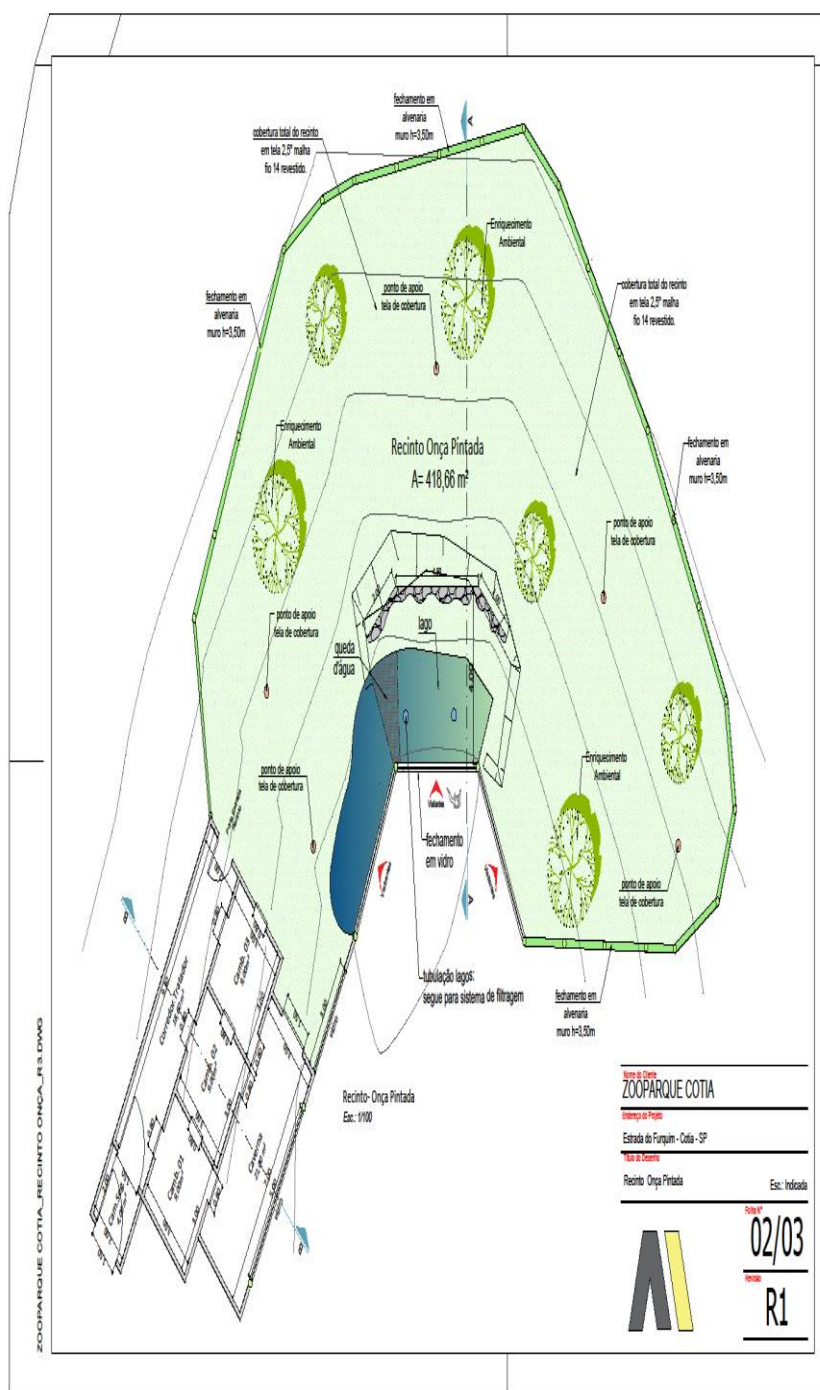


FIGURA 12. Ilustração da planta baixa do recinto dos exemplares de onças-pintada (*Panthera onca*).




FIGURA 13. Foto do recinto dos exemplares de onças-pintada (*Panthera onca*).

Recinto dos exemplares de tamanduás-mirins (*Tamandua tetradactyla*).

O recinto do tamanduá-mirim tem 55,22m², simulando uma grande árvore central cenográfica elaborada de concreto, com trilhas de cordas que circundam a mesma e adentram ao interior da mata, para a locomoção dos animais. O fechamento é construído com paredes de alvenaria com 1 m de altura, com sua parte superior em ângulo negativo. O design favorece uma visão em 360° da exposição por meio de uma passarela em espiral. O edifício de cambiamento contém duas salas de 1 m² por 3 m de altura cada, localizado no interior da árvore (Figuras 14,15 e 16).




FIGURA 14. Foto do exemplar de tamanduá-mirim (*Tamandua tetradactyla*).

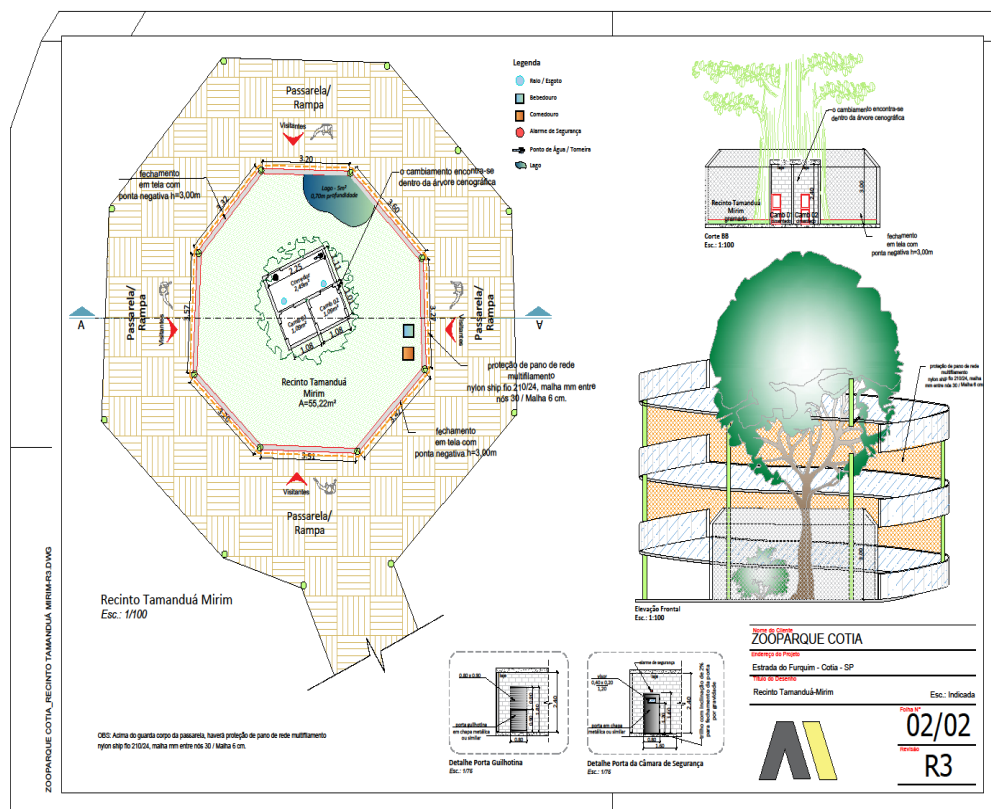


FIGURA 15. Ilustra a planta baixa do recinto dos exemplares de tamanduás-mirins (*Tamandua tetradactyla*).



FIGURA 16. Foto do recinto dos exemplares de tamanduás-mirins (*Tamandua tetradactyla*).

RESULTADOS E DISCUSSÃO

Através do presente trabalho obtivemos 2000 horas de gravação e 360.000 frames de imagens dos recintos das onças-pintadas e tamanduás-mirins. As imagens foram analisadas e mensuradas utilizando a inteligência artificial levando em consideração os padrões comportamentais de atividades (animal ativo/inativo). Para o experimento do tamanduá-mirim (*Tamandua tetradactyla*) obtivemos uma média (oito indivíduos) de inatividade de 80,84% e de atividade de 19,16 % (Tabela 2) (Gráfico 1 e 2), corroborando com CHIAPERO et al que descreve que ao longo do período de 24 horas, os tamanduás eram principalmente inativos (em média, 72,8% inativos e 27,2 % ativos) [68], mas diferindo de NETO et al que descreve menor período de inatividade (9,93% inativos e 89,7% ativos) [69]. Para o experimento da onça-pintada (*Panthera onca*) os resultados em média de padrões de atividade (dois indivíduos) foram, 91,09 % de inatividade e de 8,91% de atividade (Tabela 3). Estudos anteriores com padrão de atividade com onça-pintada (*Panthera onca*) ex-situ descrevem números semelhantes, o comportamento de descanso foi sempre a categoria comportamental mais frequente [70]. Durante as dez horas do dia (8:00-18:00), eles permaneceram ativos por apenas 2,0 horas em média (16,9% de todos os registros) [71]. Todos os sujeitos apresentaram alto índice de inatividade, sendo que alguns alcançaram 80% [72]. O ato de permanecer parado em determinado local do recinto foi o comportamento mais frequente [73]. Os métodos de amostragem utilizados nos trabalhos citados foram feitos por observações diretas.

TABELA 2. Frequência relativa e absoluta de frames de padrões de atividade/inatividade do tamanduá-mirim (*Tamandua tetradactyla*).

Dia	Inativo		Ativo	
	Frequência Absoluta de Frames	Frequência Relativa de Frames (%)	Frequência Absoluta de Frames	Frequência Relativa de Frames (%)
1	2138	85,42	365	14,58
2	44469	77,41	12977	22,59
3	2990	86,99	447	13,01
4	2068	86,56	321	13,44
5	3546	86,61	548	13,39
6	2407	80,1	598	19,9
7	4584	78,53	1253	21,47
8	1086	69	488	31
9	5055	79,02	1342	20,98
10	3170	74,4	1091	25,6
11	4364	80,58	1052	19,42
12	6703	80,86	1587	19,14
13	4784	78,48	1312	21,52
14	3062	84,84	547	15,16
15	4650	81,75	1038	18,25
16	4506	85,68	753	14,32
17	3708	85,52	628	14,48
18	5239	79,55	1347	20,45
19	3422	78,11	959	21,89
20	2629	85,05	462	14,95
21	3898	79,88	982	20,12
22	3850	85,4	658	14,6
23	2629	85,05	462	14,95
24	4938	88,57	637	11,43
25	5447	79,28	1424	20,72
26	3014	76,05	949	23,95
27	1942	67,36	941	32,64
28	1993	82,59	420	17,41
29	5823	89,53	681	10,47
30	6484	80,81	1540	19,19
31	3600	77,79	1028	22,21
32	2357	70,04	1008	29,96

Após as análises das imagens foi observado que em média, por dia, o grupo de tamanduás-mirins não estava em atividade em 5.017 frames, o que corresponde a uma média de 80,84% de inatividade por dia. Além disso, temos uma variabilidade de 53.746.417 dos frames em relação a média. Porém, observando a proporção que esta estatística oferece, temos um percentual variável de 30,09% em relação a média, o que mostra pouco distanciamento dos números de frames reais captados por dia em relação a média. Além disso, para confirmar a baixa variabilidade dos dados em relação a média, calculamos um desvio padrão de 7331 frames, o que equivalem a 5,49% de desvio em relação à média. Por fim, os valores máximo e mínimo de frames dos valores observados de inatividade da onça correspondem a 44.469 (89,53%) e 1086 (67,36%) (Figura 17 e 18).




FIGURA 17. Frequência absoluta de frames de padrões de atividade/inatividade do grupo de tamanduá-mirim (*Tamandua tetradctyla*).



FIGURA 18. Média de frequência relativa de frames de padrões de atividade/inatividade do grupo de tamanduá-mirim (*Tamandua tetradctyla*).

Como possíveis erros de detecção do animal por meio das câmeras podem ocorrer, consideraremos sem perda de informação as proporções geradas pelos números de frames registrados superiores ou iguais a 1000, em que o animal esteve inativo durante um dia. Isso aumenta o grau de confiabilidade das análises realizadas. Supondo que X é a variável que descreve a proporção de um dia que um tamanduá observado se encontra em inatividade e que X segue um modelo de distribuição de probabilidade normal com média $\mu = 80,84$ e desvio padrão 5,49, podemos calcular quantos por cento de certeza temos ao afirmar que em média o grupo de tamanduás-mirins observados permanece em inatividade 80,84% do dia. O cálculo a ser realizado é dado por: $P(67,36 < X < 89,53) = P\left(\frac{67,36-80,84}{5,49} < \frac{X-80,84}{5,49} < \frac{89,53-80,84}{5,49}\right) = P(-2,46 < Z < 1,58)$. Temos que Z segue uma normal padrão com média 0 e desvio padrão 1. Assim, $P(-2,46 < Z < 1,58) = P(Z < 1,58) - (1 - P(Z < 2,46)) = 0,9429 + 0,9948 - 1 = 0,9377$. Logo, considerando nossas suposições, podemos afirmar com 93,77% de certeza que em média em 80,84% do dia um tamanduá observado fica em inatividade. Tendo considerável certeza de que uma estimativa para a média de X é 80,84 e verificando que na nossa última tabela que contém as proporções de inatividade dos tamanduás existem mais

valores abaixo de 80,84, podemos testar as seguintes hipóteses: $H_0: \mu \leq 80,84$ e $H_1: \mu > 80,84$. Considerando o nível de significância padrão $\alpha = 0,05$, temos que rejeitamos H_0 se $Z > z_{1-0,05} \rightarrow Z > 1,64 \rightarrow \mu > 80,84 + 1,64 \times \frac{5,92}{\sqrt{32}} = 82,56$. Portanto, não há indícios de que $\mu = 80,84$ esteja fora da realidade esperada ao nível de significância $\alpha = 0,05$.

TABELA 3. Frequência relativa e absoluta de frames de padrões de atividade/inatividade da onca-pintada (*Panthera onca*).

Dia	Inativa		Ativa	
	Frequência Absoluta de Frames	Frequência Relativa de Frames (%)	Frequência Absoluta de Frames	Frequência Relativa de Frames (%)
2	5800	90,85	584	9,15
3	16709	91,86	1481	8,14
4	16647	91,63	1521	8,37
5	6490	87,63	916	12,37
6	6283	90,7	644	9,3
7	12778	94,99	674	5,01
8	8619	92,74	675	7,26
9	2238	96,38	84	3,62
10	2698	91,68	245	8,32
11	2540	94,74	141	5,26
14	4675	91,68	424	8,32
15	14130	92,75	1105	7,25
16	13780	91,76	1237	8,24
17	14604	91,61	1337	8,39
18	14369	87,79	1998	12,21
19	17408	92,82	1347	7,18
20	16913	89,23	2041	10,77
21	15913	85,58	2681	14,42
22	13215	87,38	1909	12,62
23	14728	91,2	1421	8,8
24	16001	93,4	1131	6,6
25	14479	93,18	1060	6,82
26	5768	98,58	83	1,42
27	14445	88,9	1804	11,1
28	13539	84,97	2395	15,03
29	11297	87,16	1664	12,84
32	14445	88,9	1804	11,1
33	6026	89,04	742	10,96

34	10703	88,08	1448	11,92
35	9729	91,99	847	8,01
36	5803	90,93	579	9,07
37	6504	91,62	595	8,38
38	4301	94,57	247	5,43
39	11086	87,78	1543	12,22
40	7065	89,46	832	10,54
41	12508	88,23	1669	11,77
42	12076	92,82	934	7,18
43	7135	91,84	634	8,16
44	7625	92,08	656	7,92
45	6422	95,24	321	4,76

Já para a espécie onça-pintada em média, por dia, os animais não estavam em atividade em 10.437 frames, o que corresponde a uma média de 91% de inatividade por dia. Além disso, temos uma variabilidade de 21.228.110 dos frames em relação a média. Porém, observando a proporção que esta estatística oferece, temos um percentual variável de 9% em relação a média, o que mostra pouco distanciamento dos números de frames reais captados por dia em relação a média. Além disso, para confirmar a baixa variabilidade dos dados em relação a média, calculamos um desvio padrão de 4607 frames, o que equivalem a 2,94% de desvio em relação à média. Por fim, os valores máximo e mínimo de frames dos valores observados de inatividade da onça correspondem a 17408 (98,58%) e 2238 (84,97%) (Figura 19 e 20).




FIGURA 19. Frequência absoluta de frames de padrões de atividade/inatividade da onça-pintada (*Panthera onca*).




FIGURA 20. Média de frequência relativa de frames de padrões de atividade/inatividade da onça-pintada (*Panthera onca*).

Supondo que Y é a variável que descreve a proporção de um dia que uma onça-pintada observada se encontra em inatividade e que Y segue um modelo de distribuição de probabilidade normal com média $\mu_1 = 91,09$ e desvio padrão 2,94, podemos calcular quantos por cento de certeza temos ao afirmar que em média uma onça observada está em inatividade 80,84% do dia. O cálculo a ser realizado é dado por: $P(84,97 < Y < 98,58) = P\left(\frac{84,97-91,09}{2,94} < \frac{Y-91,09}{2,94} < \frac{98,58-91,09}{2,94}\right) = P(-2,08 < Z < 2,55)$. Temos que Z segue uma normal padrão com média 0 e desvio padrão 1. Assim, $P(-2,08 < Z < 2,55) = P(Z < 2,55) - (1 - P(Z < 2,08)) = 0,9946 + 0,9812 - 1 = 0,9758$. Logo, considerando nossas suposições, podemos afirmar com 97,58% de certeza que em média em 91,09% do dia uma onça observada fica em inatividade. Tendo considerável certeza de que uma estimativa para a média de Y é 91,09 e verificando que na nossa última tabela que contém as proporções de inatividade das onças existem mais valores acima de 91,09, podemos testar as seguintes hipóteses: $H_0: \mu_1 \geq 91,09$ e $H_1: \mu_1 < 91,09$. Considerando o nível de significância padrão $\alpha = 0,05$, temos que rejeitamos H_0 se $Z < -z_{1-0,05} \rightarrow Z < -1,64 \rightarrow \mu_1 < 91,09 - 1,64 \times \frac{2,94}{\sqrt{40}} = 90,33$. Portanto, não há indícios de que $\mu_1 = 90,33$ esteja fora da realidade esperada ao nível de significância $\alpha = 0,05$.

O objetivo deste trabalho foi padronizar imagens (frames de comportamento) de padrões comportamentais de atividade e inatividade de duas espécies de animais selvagens mantidos sob cuidados humanos, para alimentar um programa de IA.

Ainda em relação aos dados sobre padrão de imagens / frames obtidos dos animais a proposta é verificar a possibilidade de interferir de forma positiva nos padrões comportamentais de animais selvagens mantidos sob cuidados humanos visando aumentar a qualidade de vidas dos indivíduos.

Nas últimas décadas, várias mudanças estão ocorrendo visando o bem-estar dos animais. Devido a estas demandas, as áreas de ambiência, bem-estar animal e etologia foram fortalecidas, trazendo mudanças em vários aspectos desta atividade, tais como: modificações no design das instalações zootécnicas, melhoria da qualidade do ambiente animal, enriquecimento ambiental, modificações de manejo, entre outros. Métodos não invasivos podem ser úteis para obtenção de dados confiáveis sem interferir diretamente com os animais, evitando reações de estresse.

Essas novas ferramentas tecnológicas têm como objetivo gerenciar e mensurar os indicadores comportamentais, fisiológicos e de desempenho. Estas tecnologias baseiam-se nas coletas de forma automatizada gerando banco de dados que devem ser interpretados com o intuito de promover aos usuários suporte para tomadas de decisão. A popularidade dos dispositivos móveis tem impulsionado a coleta de dados, graças à possibilidade de se associar a metodologia de coleta de dados em formulário com softwares livres. Isso apresenta uma alternativa econômica e ambientalmente amigável, uma vez que os dispositivos móveis eliminam a necessidade de papel, impressão e tempo gasto em transcrições.

A comunicação é acelerada e os erros cometidos durante as transcrições são reduzidos, oferecendo resultados de pesquisa mais confiáveis e permitindo a disseminação de informações geradas de forma mais rápida. Além disso, é possível utilizar diferentes mídias para o registro de dados, como fotografias, vídeos, áudios, coordenadas geográficas e altitude, o que é especialmente útil em análises de dados. Tradicionalmente, a pesquisa de comportamento requer muitas horas de treinamento para identificação correta do comportamento com base em etogramas claros e detalhados. No entanto, a tecnologia atual permite tempos de monitoramento mais longos, resultando em coleta de dados em massa, sem a necessidade de observadores humanos.

A inteligência artificial pode ser aplicada a grandes grupos de animais, incluindo espécies difíceis de amostrar e espécies que cobrem uma grande área, fornecendo informações importantes sobre seu comportamento e biologia. Em resumo, os avanços tecnológicos

são fundamentais para a obtenção de informações importantes sobre as espécies animais certamente esse é o embrião das novas condutas de análise de animais selvagens mantidos sob cuidados humanos, antes mesmo de ocupar recintos com animais selvagens, serão necessários estudos prévios em relação ao padrão de atividade, comportamento biológico da espécie animal, identificação de indivíduos, design dos recintos, manejo entre outros parâmetros em jardins zoológicos e aquários.

Realizamos o padrão de atividade para duas espécies, mas o zoológico abriga inúmeras espécies, a proposta é estender esta dinâmica para todos as espécies de animais e recintos do zoológico. Quando conseguirmos padronizar padrões de inatividade/atividade (comportamento animal) para os demais recintos/animais do zoo, poderemos interferir nesse padrão, visando o bem-estar do animal. Por exemplo aumentando a atividade em 15 a 20% e em determinado horário do dia, baseado na biologia de cada espécie.

Desta forma não há interferências significativas no comportamento animal durante as 24 hrs. Ou seja, o animal pode permanecer a maior parte do tempo em inatividade, ainda mais porque essa é a característica da espécie, mas no período noturno ou durante o período sem a presença do público ou nos horários de menor visitação. E por fim o animal repete em ambiente artificial o que ele de fato performa na natureza. Em ambiente natural os grandes felinos permanecem maior parte do dia em inatividade.

O presente trabalho é um dos primeiros no mundo e com certeza o primeiro no Brasil a ser realizado utilizando IA no monitoramento de animais selvagens mantidos sob cuidados humanos, estamos vivendo a quarta revolução a era da tecnologia, e no monitoramento comportamental não é diferente, todas as pesquisas terão a quantidade e qualidade de dados totalmente diferentes das de até então, quanto mais informações e mais confiabilidade nos dados das pesquisas maiores níveis de bem-estar poderemos proporcionar para os animais selvagens.

REFERÊNCIAS

- [1] EAZA, T. (2013). The modern zoo: Foundations for management and development, 2(1), 8-13.

[2] Mellor, D. J., Hunt, S., & Gusset, M. (2015). Caring for wildlife. The world zoo and aquarium animal welfare strategy. Gland, Switzerland: World Association of Zoos and Aquariums (WAZA) Executive Office, 5-10.

[3] Conway, W. G. (2011). Buying time for wild animals with zoos. *Zoo Biology*, 30(1), 1-8.

[4] Mellor, D. J. (2016). Updating animal welfare thinking: Moving beyond the “Five Freedoms” towards “a Life Worth Living”. *Animals*, 6(3), 21 p.

[5] Conde, D. A., Flesness, N., Colchero, F., Jones, O. R., & Scheuerlein, A. (2011). An emerging role of zoos to conserve biodiversity. *Science*, 331(6023), 1390-1391.

[6] Fa, J. E., Gusset, M., Flesness, N., & Conde, D. A. (2014). Zoos have yet to unveil their full conservation potential. *Animal Conservation*, 17(2), 97-100.

[7] Anderson, U. S., Kelling, A. S., & Maple, T. L. (2008). Twenty-five years of Zoo Biology: A publication analysis. *Zoo Biology*, 27(6), 444-457.

[8] Irwin, M. D., Stoner, J. B., Cobaugh, A. M. (2013). *Zookeeping: An introduction to the science and technology*, Chicago: University of Chicago Press, 1(1), 886 p.

[9] Hutchins, M., Wiese, R. J., & Smith, B. (2019). Research in zoos and aquariums: Purpose, justification, utility, and welfare. U AB Kaufman, MJ Bashaw, TL Maple (Ur.), *Scientific Foundations of Zoos and Aquariums: Their Role in Conservation and Research*, 1-42.

[10] Gusset, M., & Dick, G. (2010). ‘Building a Future for Wildlife’? Evaluating the contribution of the world zoo and aquarium community to in situ conservation. *International Zoo Yearbook*, 44(1), 183-191.

[11] Breed, M. D., & Moore, J. (2021). *Animal behavior*. Academic Press, 3 (1), 600.

- [12] Huntingford, F. (Ed.). (2012). The study of animal behaviour. Springer Science & Business Media, 1 (1), 412.
- [13] Fraser, D. (2009). Animal behaviour, animal welfare and the scientific study of affect. *Applied Animal Behaviour Science*, 118(3-4), 108-117.
- [14] Del-Claro, K., Prezoto, F., & Sabino, J. (2004). Comportamento animal. Uma introdução à ecologia comportamental. Jundiaí: Livraria Conceito, 11-15.
- [15] Manning, A., & Dawkins, M. S. (1998). An introduction to animal behaviour. Cambridge University Press, 6 (1), 467 p.
- [16] Volpato, G. H., Mendonça-Lima, A. (2002). Estratégias de forrageamento: Proposta de termos para a língua Portuguesa. *Ararajuba*, 10(1), 101-105.
- [17] Alcock, J. (2016). Comportamento animal: Uma abordagem evolutiva. Artmed editora, 9(1), 10-18.
- [18] Snowdon, C. T. (1999). O significado da pesquisa em comportamento animal. *Estudos de Psicologia (Natal)*, 4, 365-373.
- [19] Ferraz, M. R. (2011). Manual de comportamento animal. Editora Rubio, 1(1), 1-224.
- [20] Maple, T. L., & Perdue, B. M. (2013). Zoo animal welfare. Berlin, Germany: Springer, 14 (1), 21-33.
- [21] Gonyou, H. W. (1994). Why the study of animal behavior is associated with the animal welfare issue. *Journal of Animal Science*, 72(8), 2171-2177.
- [22] Adania, C.H; Silva, J.C.; Felipe, P.A.N. (2014). Carnivora-felidae (onça, suçuarana, jaguatirica, e gato-do-mato). In: Cubas, Z.S., Silva, J.C.R.; Catão-Dia, J.L. Tratado de animais selvagens-medicina veterinária. 2 ed. Roca; 779-818.

[23] Walker, E. P., Warnick, F., Hamlet, S. E., Lange, K. I., Davis, M. A., Uible, H. E., Paradiso, J. L. (1975). Mammals of the world. Volumes I and II (No. 3rd edition). Johns Hopkins University Press, 3(1), 1500 p.

[24] Morato, R. G., de Mello Beisiegel, B., Ramalho, E. E., de Campos, C. B., & Boulhosa, R. L. P. (2013). Avaliação do risco de extinção da onça-pintada *Panthera onca* (Linnaeus, 1758) no Brasil. Biodiversidade Brasileira, 3(1), 122-132.

[25] MMA (Ministério do Meio Ambiente-Brasil). (2014). Portaria nº 444 de 17 de dezembro de 2014. Lista Oficial das Espécies da Fauna Brasileira Ameaçadas de Extinção.

[26] Hayssen, V. (2011). *Tamandua tetradactyla* (Pilosa: Myrmecophagidae). Mammalian Species, 43(875), 64-74.

[27] Trovati, R. G., & Brito, B. D. (2009). Nota sobre deslocamento e área de uso de tamanduá-mirim (*Tamandua tetradactyla*) translocado no cerrado brasileiro. Neotropical Biology and Conservation, 4(3), 144-149.

[28] Desbiez, A. L. J., & Medri, Í. M. (2010). Density and habitat use by giant anteaters (*Myrmecophaga tridactyla*) and southern tamanduas (*Tamandua tetradactyla*) in the Pantanal wetland, Brazil. Edentata, 11(1), 4-10.

[29] Silveira, L. F., Soares, E. S., & Bianchi, C. A. (2008). Plano de ação nacional para conservação dos galliformes ameaçados de extinção. ICMBio MMA, 88 p.

[30] Miranda, F., Fallabrino, A., Arteaga, M., Tirira, D. G., Meritt, D. A., & Superina, M. (2014). *Tamandua tetradactyla*. The IUCN Red List of Threatened Species, T21350A47442916.

[31] Gomes, D. D. S. (2010). Inteligência Artificial: conceitos e aplicações. Revista Olhar Científico, 1(2), 234-246.

[32] Kaufman, D. (2019). A inteligência artificial irá suplantará a inteligência humana? Estação das Letras e Cores, 1(1), 96 p.

[33] Garcia, A. C. (2020). Ética e inteligência artificial. Computação Brasil, (43), 14-22.

[34] Russell, S. J., Norvig, P. (2004). Inteligência artificial: Um enfoque moderno, 8(4), 45-60.

[35] Lee, K. F. (2018). As Superpotências da Inteligência Artificial: a China. Silicon Valley e a Nova Ordem Mundial. Trad. Maria Eduarda Cardoso. Lisboa: Relógio D'Água Editores, 3(1), 32-40.

[36] Gunning, D., Stefik, M., Choi, J., Miller, T., Stumpf, S., Yang, G-Z. (2019). XAI Explainable artificial intelligence. Science Robotics, 4(37), 7120 p.

[37] Hinton, G. E., Osindero, S. & Teh, Y. W. (2006) A fast learning algorithm for deep belief nets. Neural Comput. 18, 1527–1554.

[38] Berchane, N. (2018). Artificial intelligence, machine learning, and deep learning: Same context, different concepts. Master Intelligence Economique et Stratégies Compétitives [en ligne], 8-12.

[39] LeCun, Y., Bengio, Y., Hinton, G. (2015). Deep learning. Nature, 521(7553), 436-444.

[40] Shinde, P. P., & Shah, S. (2018). A review of machine learning and deep learning applications. In 2018 Fourth international conference on computing communication control and automation (ICCUBEA) (pp. 1-6). IEEE.

[41] Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep learning. MIT press, 1(1), 800 p.

[42] Rusk, N. (2016). Deep learning. Nature Methods, 13(1), 35-35.

[43] Osório, F. S., & Bittencourt, J. R. (2000). Sistemas inteligentes baseados em redes neurais artificiais aplicados ao processamento de imagens. In I Workshop de inteligência artificial, 30 p.

[44] Kelleher, J. D. (2019). Deep learning. MIT press, 1(1), 54-60.

[45] Loesch, C., Sari, S. T. (1996). Redes neurais artificiais: fundamentos e modelos. Ed. da FURB, 1(1), 50 p.

[46] Pak, M., & Kim, S. (2017). A review of deep learning in image recognition. In 2017 4th International conference on computer applications and information processing technology (CAIPT) (pp. 1-3). IEEE.

[47] Min, S., Lee, B., & Yoon, S. (2017). Deep learning in bioinformatics. Briefings in Bioinformatics, 18(5), 851-869.

[48] Haykin, S. (1999). Self-organizing maps. Neural networks-A comprehensive foundation, 2nd edition, Prentice-Hall, 1(1) 643-651.

[49] Yan, L. C., Yoshua, B., & Geoffrey, H. (2015). Deep learning. Nature, 521(7553), 436-444.

[50] Bengio, Y., Goodfellow, I., Courville, A. (2017). Deep learning (Vol. 1). Cambridge, MA, USA: MIT press, 1(1), 800.

[51] Mendel, J. M., McLaren, R. W. (1970) Reinforcement-learning control and pattern recognition systems. In Mathematics in Science and Elsevier, Engineering 66, 287-318.

[52] Gu, D., Shen, J., & Wang, X. (2018). Deep learning. Instructor, 1(1), 14.

[53] Li, Y. (2022). Research and application of deep learning in image recognition. In 2022 IEEE 2nd International Conference on Power, Electronics and Computer Applications (ICPECA) (pp. 994-999). IEEE.

[54] Wang, S., Niu, L., & Li, N. (2018). Research on image recognition of insulators based on YOLO algorithm. In 2018 international conference on power system technology (POWERCON) (pp. 3871-3874). IEEE.

- [55] Fujiyoshi, H., Hirakawa, T., & Yamashita, T. (2019). Deep learning-based image recognition for autonomous driving. *IATSS Research*, 43(4), 244-252.
- [56] Bao, J., & Xie, Q. (2022). Artificial intelligence in animal farming: A systematic literature review. *Journal of Cleaner Production*, 331, 129956.
- [57] Coulson, R. N., Folse, L. J., & Loh, D. K. (1987). Artificial intelligence and natural resource management. *Science*, 237(4812), 262-267.
- [58] Stricklin, W. R., De Bourcier, P., Zhou, J. Z., & Gonyou, H. W. (1998). Artificial pigs in space: using artificial intelligence and artificial life techniques to design animal housing. *Journal of Animal Science*, 76(10), 2609-2613.
- [59] Valletta, J.J.; Torney, C.; Kings, M.; Thornton, A.; Madden, J. (2017) Applications of machine learning in animal behaviour studies. *Animal Behaviour*, 124, 203–220.
- [60] Bezerra, B.M.; Bastos, M.; Souto, A.; Keasey, M.P.; Eason, P.; Schiel, N.; Jones, G. (2014), Camera trap observations of nonhabituated critically endangered wild blonde capuchins, *Sapajus flavius* (formerly *Cebus flavius*), *International Journal of Primatology*, 35, 895–907.
- [61] Parakkal, K. S., Rahul, P. M., John, R., Madhavan, S., & Reshmi, S. (2021). Management system using internet of things and artificial intelligence. In 2021 8th International Conference on Smart Computing and Communications, 215-218.
- [62] Wark, J.D.; Cronin, K.A.; Niemann, T.; Shender, M.A.; Horrigan, A.; Kao, A.; Ross, M.R. (2019) Monitoring the behavior and habitat use of animals to enhance welfare using the ZooMonitor app. *Animal Behavior and Cognition*, 6, 158–167.
- [63] Chen, P.; Swarup, P.; Matkowski, W.M.; Kong, A.W.K.; Han, S.; Zhang, Z.; Rong, H. A. (2020) study on giant panda recognition based on images of a large proportion of captive pandas. *Ecology and Evolution*, 10, 3561–3573.

[64] Congdon, J. V., Hosseini, M., Gading, E. F., Masousi, M., Franke, M., & MacDonald, S. E. (2022). The Future of artificial intelligence in monitoring animal identification, health, and behaviour. *Animals*, 12(13), 1711.

[65] Cheng, Y. H. (2019). A development architecture for the intelligent animal care and management system based on the internet of things and artificial intelligence. In 2019 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC). 78-081.

[66] Beltzung, B., Pelé, M., Renoult, J. P., Shimada, M., Sueur, C. (2022). Using artificial intelligence to analyze non-human drawings: A first step with orangutan productions. *Animals*, 12(20), 2761.

[67] Gernat, T., Jagla, T., Jones, B. M., Middendorf, M., Robinson, G. E. (2020). Automated monitoring of animal behaviour with barcodes and convolutional neural networks. *BioRxiv*, 5-11.

[68] Chiapero, F., Ferrari, H. R., Prieto, M. V., Garcia Capocasa, M. C., & Busso, J. M. (2021). Multivariate analyses of the activity pattern and behavior of the lesser anteater on open and closed days at Córdoba Zoo, Argentina. *Journal of Applied Animal Welfare Science*, 24(1), 83-97.

[69] Neto, G. D. S. F., Barros, A. C., Sobroza, T. V., Neves, P. U. C., Phillips, M. J., & Guimarães, E. F. (2020). Period of the day and food-based enrichment affect behaviour activity of *Tamandua tetradactyla* in captivity? *Pesquisa e Ensino em Ciências Exatas e da Natureza*, 4, Article-number, 5-6.

[70] Silveira, L. (2004). Ecologia comparada e conservação da onça-pintada (*Panthera onca*) e onça-parda (*Puma concolor*), no cerrado e pantanal. Tese de Doutorado em Biologia Animal. Universidade de Brasília, 240 p.

[71] Jędrzejewski, W., Vivas, I., Abarca, M., Lampo, M., Morales, L. G., Gamarra, G., ... & Breitenmoser, U. (2021). Effect of sex, age, and reproductive status on daily activity levels and activity patterns in jaguars (*Panthera onca*). *Mammal Research*, 66, 531-539.

[72] Silva, R. O. (2011). Enriquecimento ambiental cognitivo e sensorial para onças-pintadas (*Panthera onca*) sedentárias em cativeiro induzindo redução de níveis de cortisol promovendo bem-estar, Tese de Mestrado em Biologia Animal. Universidade de Brasília, Instituto de Psicologia, Departamento de Processos Psicológicos Básicos, Programa de Pós-Graduação em Ciências do Comportamento, 58 p.

[73] Camargo, J. R. P., Nascimento, E. L., & Prezoto, H. H. S. (2014). Técnicas de enriquecimento ambiental de gato-do-mato (*Leopardus guttulus*) (Schreber, 1775), em cativeiro: Um estudo de caso. CES REVISTA, 169 p.