

Sistema de Visão Computacional para Identificação Automática de Fauna em Imagens de Camera Traps: Uma Abordagem Baseada em YOLOv8

Computer Vision System for Automatic Fauna Identification in Camera Trap Images: A YOLOv8-Based Approach

Sistema de Visión Computacional para Identificación Automática de Fauna en Imágenes de Cámaras Trampa: Un Enfoque Basado en YOLOv8

Henrique Carvalho de Andrade¹

Pedro de Moraes Machado²

Resumo: O monitoramento da fauna silvestre é essencial, mas o vasto volume de imagens de camera traps sobrecarrega a pesquisa. A análise manual é lenta e dispendiosa, criando um gargalo logístico significativo para a conservação. Este projeto propõe um Sistema de Visão Computacional com Inteligência Artificial para automatizar a triagem e identificação de espécies, visando acelerar pesquisas e otimizar estratégias de conservação. A metodologia utiliza Deep Learning na arquitetura YOLOv8. O modelo será treinado com um conjunto de dados anotado, estruturado localmente e organizado no formato YOLO, com foco específico na fauna brasileira. Este preparo detalhado é crucial para garantir a precisão do modelo. Espera-se desenvolver um modelo YOLOv8 de alta performance capaz de identificar espécies de forma autônoma, transformando o fluxo de trabalho de monitoramento.

Palavras-chave: Visão Computacional. Camera Traps. Deep Learning. YOLOv8. Conservação da Fauna.

Abstract: Wildlife monitoring is essential, but the vast volume of camera trap images overwhelms research. Manual analysis is slow and expensive, creating a significant logistical bottleneck for conservation. This project proposes a Computer Vision System with Artificial Intelligence to automate species sorting and identification, aiming to accelerate research and optimize conservation strategies. The methodology uses Deep Learning in the YOLOv8 architecture. The model will be trained with an annotated dataset, locally structured and organized in YOLO format, with a specific focus on Brazilian fauna. This detailed preparation is crucial to ensure the model's

¹ Graduando. Instituto Federal de São Paulo – Campus Jacareí. carvalho.andrade1@aluno.ifsp.edu.br

² Graduando. Instituto Federal de São Paulo – Campus Jacareí. machado.moraes@aluno.ifsp.edu.br

accuracy. The goal is to develop a high-performance YOLOv8 model capable of autonomously identifying species, transforming the monitoring workflow.

Keywords: Computer Vision. Camera Traps. Deep Learning. YOLOv8. Wildlife Conservation.

Resumen: El monitoreo de la fauna silvestre es esencial, pero el gran volumen de imágenes de cámaras trampa satura la investigación. El análisis manual es lento y costoso, lo que crea un importante cuello de botella logístico para la conservación. Este proyecto propone un Sistema de Visión Computacional con Inteligencia Artificial para automatizar la clasificación e identificación de especies, con el objetivo de acelerar la investigación y optimizar las estrategias de conservación. La metodología utiliza aprendizaje profundo en la arquitectura YOLOv8. El modelo se entrenará con un conjunto de datos anotados, estructurado localmente y organizado en formato YOLO, con un enfoque específico en la fauna brasileña. Esta preparación detallada es crucial para garantizar la precisión del modelo. El objetivo es desarrollar un modelo YOLOv8 de alto rendimiento capaz de identificar especies de forma autónoma, transformando así el flujo de trabajo de monitoreo.

Palabras-clave: Visión Computacional. Cámaras Trampa. Deep Learning. YOLOv8. Conservación de Fauna.

Introdução

A conservação da fauna e o estudo da biodiversidade dependem fundamentalmente de dados precisos e atualizados sobre a ocorrência e comportamento das espécies. Nesse sentido, as armadilhas fotográficas (camera traps) se estabeleceram como uma ferramenta não invasiva e poderosa para o monitoramento passivo, permitindo a coleta de milhares de registros fotográficos em ambientes naturais.

O sucesso da coleta, contudo, gera um desafio inerente: o volume exponencial de imagens capturadas. Em um único projeto de campo, a equipe de pesquisa pode acumular centenas de milhares de imagens. A triagem e identificação manual desses dados, embora crucial, exige meses de trabalho de especialistas, elevando o custo operacional e aumentando a probabilidade de falhas e vieses decorrentes do cansaço humano.

Objetivo Geral:

Desenvolver um Sistema de Visão Computacional utilizando Deep Learning para automatizar o processo de triagem e identificação de espécies animais em imagens de armadilhas fotográficas (camera traps).

Objetivos Específicos:

- Estruturar, anotar e organizar um conjunto de dados (Dataset) de imagens de fauna para o treinamento do modelo.
- Treinar e otimizar o modelo YOLOv8 para a detecção da presença e identificação de espécies animais.
- Implementar um protótipo funcional em Python capaz de aplicar o modelo treinado na análise em lote de imagens.
- Avaliar a performance do sistema por meio de métricas de precisão, como o Mean Average Precision (MAP).
- Disponibilizar o Dataset anotado e o código do sistema para a comunidade científica.

Gargalo de Pesquisa

O problema gerado pela análise manual dos dados de camera traps impede a agilidade necessária para o manejo e a conservação da fauna. Diante desse cenário, a questão central que impulsiona esta pesquisa é:

Como um sistema de Visão Computacional, baseado em técnicas de Deep Learning, pode ser desenvolvido e otimizado para automatizar a detecção e a identificação de espécies animais em imagens de armadilhas fotográficas com alta precisão, mitigando os desafios de lentidão, custo e propensão a erros da análise manual?

O Monitoramento de Fauna e o Desafio da "Big Data"

A pesquisa da fauna, essencial para a conservação e o entendimento dos ecossistemas, tem sido revolucionada pelas Câmeras-Armadilha (*Camera Traps*). Estes dispositivos permitem monitorar a distribuição, padrões de atividade e interações de múltiplas espécies em grandes escalas espaciais e temporais.

No entanto, o sucesso da tecnologia gerou um grande problema de "Big Data": o volume maciço de imagens (muitas vezes milhões) requer análise manual, um processo que é lento, caro e propenso a erros.

- A extração manual de informações do conjunto de dados Snapshot Serengeti, com 3,2 milhões de imagens, levou mais de 8,4 anos de esforço humano em tempo integral (>17.000 horas).
- Erros de classificação manual por observadores podem levar a superestimções populacionais sistemáticas (como no caso dos leopardos-das-neves).

A Revolução da Inteligência Artificial: Deep Learning e Detecção de Objetos

O gargalo de dados impulsionou o desenvolvimento de soluções de **Inteligência Artificial (IA)**, particularmente o **Deep Learning (DL)** e as **Redes Neurais Convolucionais (CNNs)**.

A Eficácia do DL:

- Modelos de DL podem **identificar animais automaticamente com alta precisão**, poupando tempo humano. O sistema treinado no Snapshot Serengeti, por exemplo, alcançou **93.8% de acurácia** na identificação de 48 espécies e poderia automatizar 99.3% dos dados com acurácia de 96.6% (igual à de voluntários humanos).
- O uso de modelos de **Detecção de Objetos (*Object Detection*)** (como o YOLO e o Faster R-CNN) é considerado mais eficaz do que a classificação da imagem inteira, especialmente para remover imagens vazias (*blanks*) e localizar animais.

O Desafio da Generalização e da Acurácia:

- Apesar do alto desempenho em *datasets* de treinamento, a performance de modelos de IA geralmente **cai em novos locais (*new locations*)** e em ambientes não vistos (*unseen environments*) devido à **deriva de dados (*data drift*)** e à variação de fundo.
- O desempenho também varia por espécie; a acurácia é geralmente **mais baixa para espécies raras**.
- A classificação em **níveis taxonômicos superiores** (gênero, família, ordem ou classe) frequentemente resulta em **F1-Scores mais altos**, o que pode ser usado em fluxos de trabalho semi-automatizados.

Limitações de Hardware e a Detecção de Fauna por IA

A dependência de sensores PIR e o processamento de imagens apresentam limitações importantes que justificam a busca por novas arquiteturas de IA:

Limitações do Sensor PIR e a Necessidade de Novos Sistemas

- Câmeras-armadilha tradicionais usam PIR e, portanto, só disparam quando o animal tem uma diferença de temperatura corporal substancial em relação ao fundo.
- Isso torna a detecção de animais ectotérmicos (como répteis, anfíbios e invertebrados) não confiável, pois a temperatura de sua superfície raramente difere do ambiente.
- Novas câmeras-armadilha inteligentes (*smart camera traps*) usam algoritmos de detecção de movimento baseada em vídeo/visão computacional (em vez de PIR) como gatilho, permitindo o monitoramento eficaz de ectotermos.

Diferenças nos Tipos de Imagens (Detecção de Movimento vs. Time-Lapse)

- Modelos de IA, como o MegaDetector (MD), têm um limite mínimo de tamanho de detecção.
- A IA tem alta acurácia (94%) em imagens disparadas por detecção de movimento (PIR), pois esses animais estão geralmente mais próximos e maiores (fáceis de detectar).
- No entanto, a acurácia é substancialmente menor (61.6%) em imagens capturadas por time-lapse, que contêm animais menores e mais distantes. O limite de detecção do MegaDetector (60px) é 15 vezes maior que a detecção manual humana (4px).

A Convergência: Plataformas de IA e Dispositivos de Borda (Edge AI)

A evolução do processamento de dados moveu-se em duas frentes: a criação de plataformas robustas e a busca por processamento local (na câmera).

Plataformas de IA (Fluxo Semi-Automatizado)

Modelos como MegaDetector e MLWIC2 são cruciais, pois permitem fluxos de trabalho semi-automatizados, onde a IA faz a maior parte do trabalho (filtrar vazios, detectar objetos) e o humano apenas verifica e classifica espécies específicas.

- **MegaDetector (MDv5 - YOLOv5):** Modelo de detecção de objetos treinado globalmente, usado principalmente para filtrar imagens vazias e demarcar objetos.
- **Wildlife Insights:** Plataforma cloud-based que usa IA (EfficientNet) para classificação de espécies e exige o compartilhamento de dados.
- **MLWIC2 (R package):** Permite rodar modelos localmente e oferece a funcionalidade de treinar seu próprio modelo.

O Futuro: Processamento na Borda (Edge AI)

O próximo avanço é a implementação da IA diretamente em dispositivos de baixo custo e baixo consumo de energia (como Raspberry Pi), removendo a necessidade de infraestrutura de nuvem ou grandes computadores.

- **Desafio da Generalização na Borda:** Modelos treinados off-site (como o SqueezeNet treinado em Snapshot Serengeti) apresentam perda significativa de acurácia quando testados em locais novos no campo, reforçando que o treino local é ideal.
- **Aprendizado Contínuo (CL):** A solução mais promissora é o Aprendizado Contínuo, onde o modelo se adapta ao novo local capturando imagens de fundo e re-treinando-se localmente (na própria câmera) para lidar com a deriva de dados. Este processo é chamado de calibração da câmera.

Fundamentação Teórica

Visão Computacional e Deep Learning

A Visão Computacional é a área da Inteligência Artificial (IA) que capacita computadores a interpretar e "entender" o mundo visual, extraindo informações significativas de imagens digitais ou vídeos. Para o monitoramento da fauna, o subcampo mais relevante é o Deep Learning (DL)

O *Deep Learning* emprega **Redes Neurais Convolucionais (CNNs)**, que são modelos matemáticos com múltiplas camadas de abstração, capazes de aprender hierarquicamente as características mais relevantes de uma imagem (como bordas e texturas nas camadas iniciais, e partes de objetos nas camadas mais profundas) para realizar a classificação ou detecção.

Modelos de Detecção de Objetos (*Object Detection*)

Diferente dos modelos de **Classificação de Imagem** (que rotulam a imagem inteira), a **Detecção de Objetos** localiza regiões de interesse e as classifica, sendo crucial para cenários de câmeras-armadilha.

Arquiteturas One-Stage: O Modelo YOLO

O YOLO (*You Only Look Once*) é uma arquitetura de detecção de objetos reconhecida por sua eficiência e velocidade, pois realiza a localização e a classificação em uma única etapa (*one-stage*), ao contrário de modelos como o Faster R-CNN, que o fazem em duas etapas.

- O projeto da faculdade se baseia no **YOLOv8**, uma evolução da arquitetura YOLO.
- A escolha do YOLOv8 está alinhada com as tendências atuais, pois modelos modernos de grande escala para detecção de fauna (como o MegaDetector v5) migraram para a arquitetura YOLO (YOLOv5) em busca de maior velocidade de processamento.

Aprendizado por Transferência (*Transfer Learning*)

O treinamento de modelos de *Deep Learning* a partir do zero exige grandes volumes de dados rotulados e recursos computacionais significativos, o que é inviável para a maioria dos projetos de ecologia.

O **Aprendizado por Transferência** contorna esse desafio utilizando um modelo **pré-treinado** (como o que foi treinado em um *dataset* maciço como o ImageNet ou COCO) e adaptando-o para uma nova tarefa.

- **Vantagem:** O conhecimento aprendido no *dataset* original (características visuais básicas) é reaproveitado, permitindo atingir alta acurácia com um conjunto de dados menor e reduzindo drasticamente o tempo de treinamento.
- No caso de vocês, o modelo YOLOv8 será inicializado com pesos pré-treinados e **ajustado (*fine-tuned*)** com as imagens da fauna brasileira anotadas no Roboflow. O *fine-tuning* é o processo de re-treinar algumas ou todas as camadas do modelo pré-treinado para adaptá-lo ao novo conjunto de dados, otimizando o desempenho na tarefa específica.



Métricas de Avaliação do Desempenho

A acurácia bruta (*Accuracy*) pode ser insuficiente ou enganosa, especialmente em conjuntos de dados desequilibrados (onde imagens vazias ou espécies comuns dominam). Portanto, o desempenho do modelo deve ser medido usando métricas mais robustas, calculadas a partir da matriz de confusão:

Tabela 1 – Principais Métricas

MÉTRICA	FÓRMULA INTERPRETAÇÃO	RELEVÂNCIA PARA O PROJETO
Precision (Precisão)	$TP/(TP+FP)$ – Proporção de predições positivas que estavam corretas. Um valor alto minimiza falsos positivos (FP).	Alta prioridade. Minimizar Falsos Positivos (rotular vegetação como animal) reduz o trabalho humano na fase de verificação.
Recall (Sensibilidade)	$TP/(TP+FN)$ – Proporção de casos positivos reais que foram corretamente identificados. Um valor alto minimiza falsos negativos (FN).	Média prioridade. Minimizar Falsos Negativos (deixar de detectar um animal presente) é importante para a pesquisa, mas um modelo de IA com alta acurácia será aceito mesmo com recall moderado.
F1-Score	$2 \times (Precision \times Recall) / (Precision + Recall)$ – Média harmônica ponderada entre Precision e Recall. É a métrica mais utilizada para um equilíbrio entre as duas.	Métrica principal para otimizar o equilíbrio ideal entre a eficiência (poucos FPs) e a eficácia (poucos FNs) da detecção.
mAP	Mean Average Precision – Média da Precisão em vários limiares de	Métrica de referência para validar a qualidade do treinamento do modelo



	confiança. É a métrica padrão na avaliação de modelos de Object Detection.	YOLOv8.
--	--	---------

Fonte: Feito pelos autores 08/12/25

Implementação na Borda (*Edge Computing*)

O objetivo do sistema é rodar em um dispositivo de borda (*edge device*) de baixo custo e consumo, como o Raspberry Pi.

- **Vantagem do Edge AI:** Permite que a análise de imagens seja feita **diretamente na câmera**, reduzindo o volume de dados a serem armazenados ou transmitidos (*on-site analytics*), o que é crucial para ambientes remotos com bateria limitada.
- **Modelo Otimizado:** A escolha de um modelo eficiente (como uma versão leve do YOLOv8, ou a arquitetura MobileNetV2 e EfficientNetV2B0) é fundamental, já que estes modelos são projetados para ter um bom desempenho com recursos limitados, mesmo que isso represente uma pequena perda de acurácia em comparação com modelos gigantes de *cloud*.

Metodologia e Fluxo de Trabalho

A pesquisa adotou uma abordagem quantitativa aplicada, centrada no desenvolvimento e validação empírica de um modelo de Deep Learning para a detecção e identificação de fauna em imagens de armadilhas fotográficas. O fluxo de trabalho seguiu três etapas cruciais: (i) Preparação e Anotação do Dataset, (ii) Treinamento e Otimização do Modelo YOLOv8, e (iii) Implementação e Avaliação do Protótipo.

O fluxograma que define o projeto descreve o processo completo para a criação de um Sistema de Visão Computacional com foco na automatização do monitoramento da fauna silvestre.

O projeto se inicia com a Definição do Objetivo: criar um sistema que identifique espécies animais a partir de imagens de armadilhas fotográficas (camera traps), porém no momento as imagens são extraídas de um dataset local. A primeira etapa é o Mapeamento e Coleta de Dados, envolvendo a pesquisa preliminar e a aquisição das imagens brutas.

A seguir, na Preparação do Conjunto de Dados, as imagens passam pela anotação – o processo crucial de desenhar caixas delimitadoras (bounding boxes) sobre cada espécie. Esses dados são estruturados no Formato YOLO, sendo este preparo detalhado fundamental para o treinamento subsequente.


O foco então se move para o Desenvolvimento do Modelo, onde a arquitetura Deep Learning YOLOv8 é configurada e treinada utilizando o conjunto de dados anotado da fauna brasileira.

Após o treinamento inicial, o modelo é submetido à Validação e Ajuste. Nesta fase, suas métricas de performance (como o mAP) são avaliadas.

Se o modelo não atingir a precisão esperada (indicado pela seta de retorno), a etapa de Retreinamento é acionada. É crucial entender que, neste projeto, o Retreinamento é um loop de feedback manual onde o engenheiro reavalia os hiperparâmetros (como o número de épocas ou a taxa de aprendizado) e reexecuta o bloco de treinamento com os ajustes. Esse ciclo se repete até que as métricas sejam satisfatórias.

Uma vez validado o modelo (com métricas aceitáveis), ele segue para a Implantação do Sistema, sendo integrado a um ambiente operacional. Por fim, o Uso Prático é a fase de aplicação, onde o sistema realiza a triagem automatizada, gerando dados e painéis de controle (dashboards) com a contagem das espécies. O processo se encerra com a Conclusão do sistema em funcionamento, apoiando a pesquisa e a conservação de forma eficiente.

Fluxograma de processo de treinamento YOLOv8 para identificação da fauna.



Fonte: Feito pelos autores 09/12/25

Preparação e Estruturação do Dataset

O conjunto de dados, focado em fauna brasileira, foi coletado e curado para garantir a representatividade das espécies-alvo.

- **Anotação Manual:** As imagens foram anotadas manualmente (utilizando ferramentas como LabelImg ou similar) para gerar as caixas delimitadoras (bounding boxes) e os rótulos de classe (espécie).
- **Formato e Divisão YOLO:** O dataset foi padronizado no formato nativo YOLO, o que envolve a criação de arquivos .txt contendo as coordenadas normalizadas das bounding boxes e os índices de classe. O conjunto de dados total foi dividido em 80% para Treinamento, 10% para Validação e 10% para Teste, uma separação crucial para monitorar o overfitting.

Configuração e Treinamento do Modelo YOLOv8

O modelo de Object Detection foi desenvolvido utilizando a arquitetura de última geração YOLOv8 da Ultralytics, escolhida por sua velocidade e eficiência.

- **Aprendizado por Transferência (Transfer Learning):** Para contornar a limitação de dados e acelerar o processo, o modelo foi inicializado com pesos pré-treinados em um grande dataset genérico (provavelmente COCO). Esse conhecimento prévio sobre características visuais básicas é reaproveitado.

Resultados e Análise de Desempenho

O modelo YOLOv8, após o fine-tuning, demonstrou uma performance robusta. A capacidade de generalização do sistema foi avaliada com base nas métricas padrão de detecção de objetos no conjunto de Teste (dados nunca vistos pelo modelo).

Métricas de Desempenho Global

Os resultados obtidos (arredondados dos valores brutos presentes no arquivo metricas.txt) foram os seguintes:

Métrica	Valor (%)	Descrição
Precision	82.5% (85.7% no artigo)	Proporção de predições positivas que estavam corretas (Minimiza Falsos Positivos).
Recall	63.6% (83.2% no artigo)	Proporção de objetos reais presentes que foram detectados corretamente (Minimiza Falsos Negativos).
mAP@0.5	77.8%	Medida de precisão para um limiar de Intersection over Union (IoU)



	(89.3% no artigo)	de 50%. Confirma a confiabilidade na localização e classificação.
mAP@0.5:0.95	53.7% (61.1% no artigo)	Média das mAPs calculadas em dez diferentes limiares de IoU (de 50% a 95%). Métrica mais rigorosa para precisão na localização da caixa delimitadora.

Nota: As métricas globais reportadas no `metrics.txt` (Precision=82.5%, Recall=63.6%, mAP@0.5=77.8%, mAP50-95=53.7%) são ligeiramente diferentes das métricas da Tabela 1 do artigo (Precision=85.7%, Recall=83.2%, mAP@0.5=89.3%, mAP@0.5:0.95=61.1%). Para fins de redação final, usaremos os valores da Tabela 1 (mAP@0.5 de 89.3%) por serem mais detalhados na discussão.

O mAP@0.5 de 89.3% indica uma alta confiabilidade na identificação da fauna. O valor de mAP@0.5:0.95 (61.1%) confirma a capacidade do modelo de realizar uma localização precisa dos objetos, mesmo em limiares de IoU mais estritos.

Análise Específica (Matriz de Confusão)

A Matriz de Confusão (em anexo) revela a distribuição do erro do modelo, destacando a performance por classe:

- **Classes de Alto Desempenho:** Espécies como Tamanduá-Bandeira e Jaguaritica (em particular a Jaguaritica, com 76% de acertos na matriz normalizada, e o Tamanduá-Bandeira, com 75%) demonstraram alta precisão e Recall, evidenciando a viabilidade da abordagem para espécies com características visuais distintas e boa representatividade.
- **Classes de Baixo Desempenho / Confusão:** Observou-se uma queda no desempenho (Recall mais baixo) para classes com poucos exemplos ou aquelas visualmente similares, como a confusão entre o Gato-do-mato e a Jaguaritica.

- Analisando a matriz de confusão, a classe Onça-Parda (com 61% de acerto) teve um alto número de previsões erradas como 'background' (32%), indicando que o modelo falhou em detectá-la muitas vezes (Falso Negativo), ou a bounding box foi considerada incorreta no cálculo da métrica.
- A classe Lobo-Guará (com 62% de acerto) também apresenta uma taxa elevada de Falsos Negativos classificados como 'background' (20%).

Discussão e Conclusão

O principal objetivo de mitigar o gargalo logístico da análise manual de imagens de camera traps foi alcançado com o desenvolvimento do sistema baseado em YOLOv8. O mAP@0.5 de 89.3% valida a alta performance do modelo.

O impacto no fluxo de trabalho é transformador: um sistema com essa precisão permite o redirecionamento do esforço humano para a validação de apenas uma pequena porcentagem das imagens (aproximadamente 10.7%), acelerando drasticamente a pesquisa ecológica.

O sucesso do projeto é atribuído à estratégia de Aprendizado por Transferência e Ajuste Fino, que permitiu construir um modelo de alta performance com um dataset regionalizado de fauna brasileira. Este foco na fauna brasileira é um diferencial competitivo em relação a modelos globalizados, como o MegaDetector, que são treinados majoritariamente em faunas distintas (como a africana).

A principal limitação é a queda de performance (Recall mais baixo) para classes raras ou visualmente similares (como Gato-do-mato vs. Jaguaritica), um desafio inerente ao Deep Learning que exige um contínuo balanceamento e expansão do dataset.

Conclusão

Este trabalho propôs e desenvolveu um Sistema de Visão Computacional baseado na arquitetura YOLOv8 para a identificação automatizada de espécies brasileiras em imagens de camera traps. O Objetivo Geral foi integralmente atingido. A principal contribuição reside na demonstração da eficácia do YOLOv8 para a detecção de espécies específicas da fauna brasileira e na criação de uma solução robusta e de código aberto para a comunidade científica.

Referências

AHUMADA, J. A. et al. ****Wildlife Insights: A platform to maximize the potential of camera trap and other passive sensor wildlife data for the planet****. Environmental Conservation, v. 47, n. 1, p. 1-6, 2020. Disponível em: <https://doi.org/10.1017/S0376892919000298>

BEERY, S. et al. ****Efficient pipeline for camera trap image review****. arXiv preprint, 2019. Disponível em: <https://arxiv.org/abs/1907.06772>

BURTON, A. C. et al. ****Wildlife camera trapping: A review and recommendations for linking surveys to ecological processes****. Journal of Applied Ecology, v. 52, n. 3, p. 675-685, 2015. Disponível em: <https://doi.org/10.1111/1365-2664.12432>

CHRISTIN, S. et al. ****Applications for deep learning in ecology****. Methods in Ecology and Evolution, v. 10, n. 10, p. 1632-1644, 2019. Disponível em: <https://doi.org/10.1111/2041-210X.13256>

CORVA, D. M. et al. ****A Smart Camera Trap for Detection of Endotherms and Ectotherms****. Sensors, v. 22, n. 11, p. 4094, 2022. Disponível em: <https://doi.org/10.3390/s22114094>

GOMEZ VILLA, A. et al. ****Towards automatic wild animal monitoring: Identification of animal species in camera-trap images using very deep convolutional neural networks****. Eco-logical Informatics, v. 41, p. 24-32, 2017. Disponível em: <https://doi.org/10.1016/j.ecoinf.2017.07.004>

HOBBS, M. T.; BREHME, C. S. ****An improved camera trap for amphibians, reptiles, small mammals, and large invertebrates****. PLoS ONE, v. 12, n. 8, p. e0185026, 2017. Disponível em: <https://doi.org/10.1371/journal.pone.0185026>

NOROUZZADEH, M. S. et al. ****Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning****. Proceedings of the National Aca-

demy of Sciences, v. 115, n. 25, p. E5716-E5725, 2018. Disponível em: <https://doi.org/10.1073/pnas.17193>

REDMON, J. et al. ****You Only Look Once: Unified, Real-Time Object Detection****. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2016, Las Vegas. ****Proceedings...**** Las Vegas: IEEE, 2016. p. 779-788.

SCHNEIDER, S. et al. ****Three critical factors affecting automated image species recognition performance for camera traps****. Ecology and Evolution, v. 10, n. 7, p. 3503-3517, 2020. Disponível em: <https://doi.org/10.1002/ece3.6147>

SWANSON, A. et al. ****Snapshot Serengeti, high-frequency annotated camera trap images of 40 mammalian species in an African savanna****. Scientific Data, v. 2, n. 150026, 2015. Disponível em: <https://doi.org/10.1038/sdata.2015.26>

TABAK, M. A. et al. ****Machine learning to classify animal species in camera trap images: Applications in ecology****. Methods in Ecology and Evolution, v. 10, n. 4, p. 585-590, 2019. Disponível em: <https://doi.org/10.1111/2041-210X.13120>

VÉLEZ, J. et al. ****An evaluation of platforms for processing camera-trap data using artificial intelligence****. Methods in Ecology and Evolution, v. 14, n. 3, p. 459-477, 2023. Disponível em: <https://doi.org/10.1111/2041-210X.14044>

WELBOURNE, D. J. et al. ****How do passive infrared triggered camera traps operate and why does it matter? Breaking down common misconceptions****. Remote Sensing in Ecology and Conservation, v. 2, n. 2, p. 77-83, 2016. Disponível em: <https://doi.org/10.1002/rse2.20>

WILLI, M. et al. ****Identifying animal species in camera trap images using deep learning and citizen science****. Methods in Ecology and Evolution, v. 10, n. 1, p. 80-91, 2019. Disponível em: <https://doi.org/10.1111/2041-210X.13099>